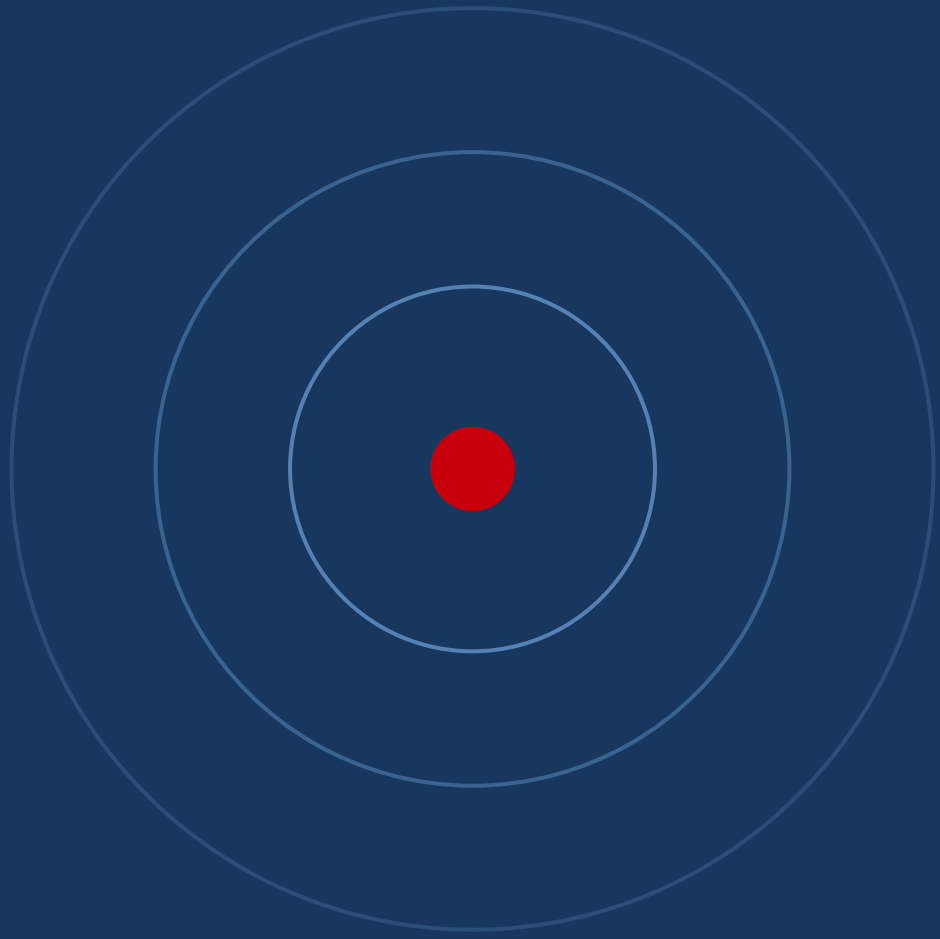
声源定位（SSL）调研 · 场景一

摄像头声源定位与持续跟踪

需求拆解 · 方案选型 · 数据集 · 12 月原型计划



汇报人：令狐雅熙　2026.11

整体方向：唤醒 + 定位 + 波束成形协同，我负责声源定位，12 月底交付可演示的原型

mentor 负责语音唤醒；声源定位分三档推进：12 月原型 → 2027 Q1 网络升级 → 视听融合与异响扩展

B0 **本期：12 月原型**

唤醒词定向 + 持续跟踪

- 唤醒后用缓存的唤醒词片段测向（SRP-PHAT + 起始段加权）
- 持续跟踪说话人，方位实时给波束成形与云台
- 离线回放 + 实时两档 demo，每周迭代

M1 **2027 Q1：精度升级**

轻量神经网络测向

- 仿真显示短时间窗 + 混响是 SRP 的短板，由网络补足
- 唤醒已判断“是不是人声”，网络先做纯测向；SELD 留给异响
- 按产品阵列几何仿真训练，真实录音微调

E1 **后续扩展**

视听融合 + 异响事件

- 视场外靠声学，视场内交给人形 / 说话人检测
- 电视误唤醒：干扰方向表 + 视觉复核
- 哭声、玻璃破碎等异响也能触发转向

接口 语音唤醒（mentor）→ 唤醒词起止时间；声源定位（我）→ 每 100 ms 方位 + 置信度；波束成形 / 云台按方位对准（波束成形分工待确认）

场景一闭环：唤醒 → 定向 → 转向与波束对准 → 视觉接管 → 持续跟踪



声学主导 唤醒、定向、波束对准：误差只要让目标进入画面中央即可

视觉主导 视场内精定位、确认是谁在说话

已有先例：华为智选海雀雀蛋 Pro “海雀海雀”唤醒后转向（双麦， 2025 ）； Amazon Echo Show 10 唤醒词转屏（已停产）； 萤石 C6C 3 麦声源定位

三技术分工与接口：唤醒给“何时”，定位给“在哪”，波束成形与云台按方位执行

接口先按下表约定，周会上逐项确认；格式可随 mentor 的唤醒模块调整

麦克风阵列
16 kHz； 2 s 环形缓存

→

语音唤醒（mentor）
检测唤醒词 → 起止时间、置信度

→

声源定位（我）
唤醒词片段测向 + 持续跟踪

→

波束成形（分工待确认）
按方位增强说话人语音

→

云台与视觉
转向、视觉确认、居中

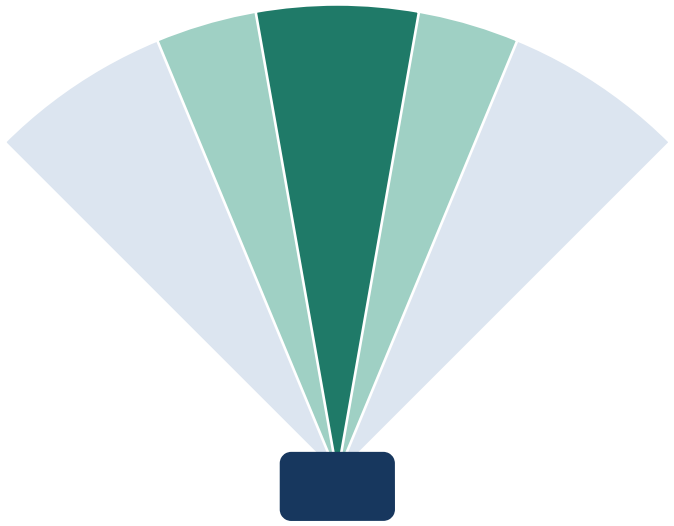
接口	内容	建议格式	状态
阵列 → 各模块	麦克风数量、几何、采样率、帧长、缓存长度	16 kHz；帧 16 ms；环形缓存 ≥ 2 s	**待确认**
唤醒 → 定位	触发时刻、唤醒词起止样点、置信度；唤醒跑在哪个通道 / 波束	回调或消息；样点级时间戳	**待对齐**
定位 → 波束成形	方位（俯仰可选）、置信度、更新时刻	每 100 ms；低置信度时保持上一方向	**待对齐**
定位 → 云台	世界坐标方位、是否转动；读取云台角与电机状态	状态机输出（死区、确认、冻结）	**原型已有**

需和 mentor 定的一个设计选择 唤醒若跑在多个固定波束上，可直接用得分最高的波束作粗方向；但 Amazon 指出波束选择不适合直接驱动转动，所以建议“先唤醒、再用唤醒词片段精确测向”。

精度要求由镜头视场反推：方位误差小于 HFOV/4，目标即落在画面中央一半

允许误差 ≤ HFOV / 4

转向后目标落在画面中央一半，就能交给视觉精对准。以 HFOV = 90° 为例，允许 ±22.5°；取 ±10° 作设计目标，为人员移动和跟踪延迟留余量。



水平视场 HFOV = 90°（示例）

中央一半：±22.5°

设计目标：±10°

建议指标（目标值待与产品需求对齐）

指标	定义	建议目标
方位误差	单声源、RT60 ≤ 0.6 s、SNR ≥ 10 dB 下的平均绝对误差	**≤ 10°**
转向命中率	转动结束后目标位于画面中央一半的比例	**≥ 90%**
粗大错误率	误差 > 45°（含前后混淆）的比例	**≤ 3%**
定向 / 转向时延	唤醒词结束 → 输出方位 / 云台开始转动	**≤ 0.1 s / ≤ 0.5 s**
误转率	无有效唤醒时的转动次数（含电视误唤醒）	**≤ 1 次 / 小时**
端侧开销	常开链路的算力、内存与功耗	**【待定】**

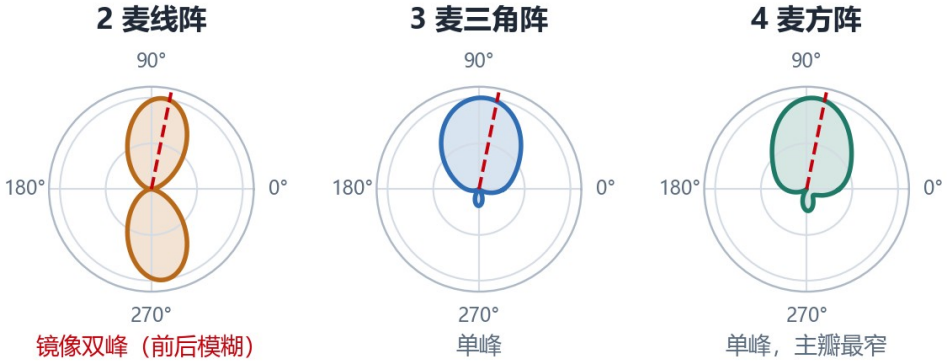
五个工程难点决定方案取舍：小孔径、混响干扰、电机自噪声、间歇多源、常开功耗

难点	对测向的影响	对策（对应模块）
1　小孔径、少阵元（2–4 麦，3–6 cm）	低频角分辨率差；间距 4 cm 时约 4.3 kHz 以上出现空间混叠；2 麦线阵前后对称，只能测 0–180°	≥ 3 麦平面阵；空间特征限定在混叠频率以下；2 麦方案借云台小角度转动消除前后模糊
2　室内混响与定向干扰（电视、音箱）	墙面反射产生伪峰；电视里的人声触发误转	PHAT 加权 + 直达声主导的时频点筛选；固定干扰方向表 + 视觉复核（无人形不跟）
3　云台电机自噪声，阵列随云台转动	转动时测向失真；阵列坐标系随转角变化	电机状态门控（转动期间冻结测向）；编码器角度换算到世界坐标；后续做电机噪声模板抑制
4　声源间歇、移动、多人同时说话	说话停顿即丢目标；多人时不确定转向谁	跟踪器静音保持；事件优先级 + 最近激活策略；多目标跟踪预研
5　常开低功耗	网络全时运行功耗高	两级触发：轻量检测常开，确认后再唤醒测向网络

注：空间混叠频率 $f = c / 2d$（$c \approx 343$ m/s，d 为阵元间距）

阵列构型先行：推荐 4 麦平面阵；若只能用 2 麦，需借云台转动消除前后模糊

	2 麦线阵	3 麦三角阵	4 麦方阵 / 圆阵
方位覆盖	0–180°（前后对称）	0–360°	0–360°
同时声源数（子空间法上限 M−1）	1	2	3
俯仰角	不可测	可测，上下对称	可测，上下对称
适配算法	GCC-PHAT、LightDOA	SRP-PHAT、神经网络	SRP-PHAT、MUSIC、4 通道 SALSA-Lite
成本	最低	中	中高
结论	低成本档，需主动消歧	可用：单声源精度接近 4 麦	**推荐**



仿真：同一声源（RT60 = 0.4 s）的 SRP-PHAT 空间谱，红色虚线为真实方向。旁证：双麦的雀蛋 Pro 评测称“正面 180° 内识别”

安装位置同样影响算法

固定在底座：阵列坐标系不变，转动中仍可测向，但需抑制电机噪声

随云台转头：测得方位须加编码器角度换算到世界坐标；转动中相当于“移动阵列”（对应 LOCATA 移动阵列任务）

孔径取舍：孔径越大角分辨率越好，但混叠频率越低（d = 5 cm 时约 3.4 kHz）；建议 5–6 cm

【待确认】产品阵元数、间距与安装位置

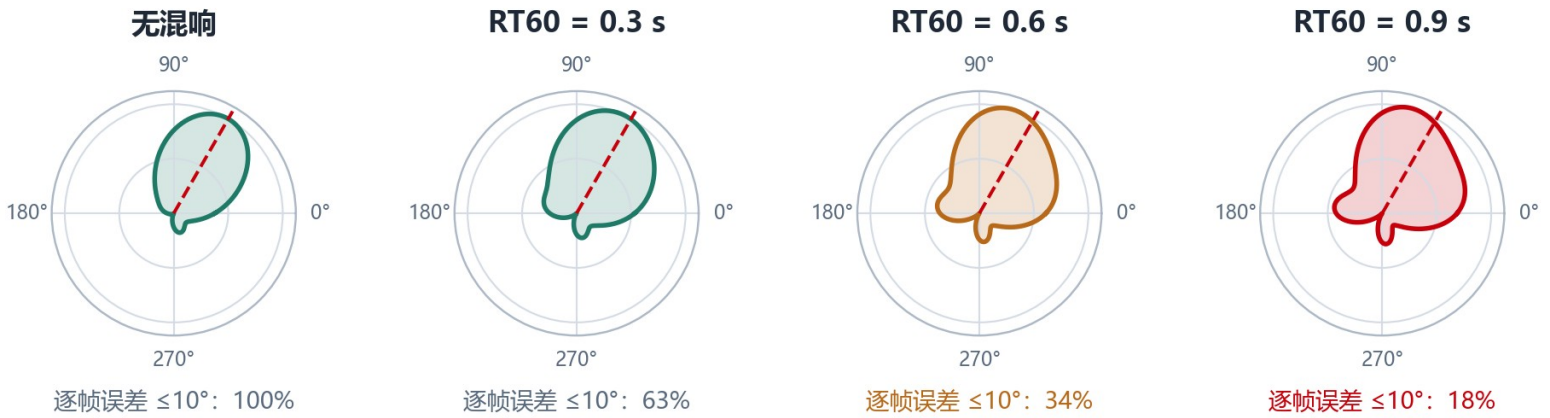
测向算法对比： 12 月原型用 SRP-PHAT； Q1 换轻量网络提升短时精度， SELD 留给异响扩展

方法（出处）	原理	混响 / 噪声鲁棒	多声源	事件类别	端侧开销	定位
GCC-PHAT	麦克风对时延估计	**中**	弱	无	极低	2 麦方案组件
SRP-PHAT （pyroomacoustics 可复现）	在 5° 网格（72 个方向）上扫描各麦克风对的 PHAT 能量	**中**	**中**	无	低	**12 月原型 B0**
NormMUSIC	子空间谱估计	弱（相干反射）	**强**	无	中（逐频点特征分解）	对照
Cross3D-Edge （ACM TECS 2023）	SRP 功率图 + 裁剪后的 3D CNN	**强**	单声源	无	127 MFLOPS；树莓派 4B 8.6 ms/ 帧	单声源备选
LightDOA （arXiv 2025）	双通道 IPD + 深度可分离卷积 + GRU， 0–180° 按 5° 分类	**中**	弱	无	低	2 麦方案备选
轻量 SELD： SALSA-Lite + 深度可分离 CRNN + Multi-ACCDOA	多通道对数谱 + 归一化 IPD，逐帧输出“类别 × 方向向量”	**强**	**强（同类重叠可分）**	**有**	中，可裁剪	**Q1 网络方向 M1 （异响时用 SELD）**
FN-SSL / IPDnet （Interspeech 2023 / 2024）	全带 - 窄带融合估计直达声 IPD，面向移动声源	**强**	**强（IPDnet）**	无	较高	精度参照 / 教师模型

评级综合各论文报告与原理分析，最终以统一测试矩阵复测为准； Neural-SRP （IEEE OJSP 2024）可适配任意阵列几何，若后续有多款硬件再引入。

初步仿真： 3/4 麦 SRP-PHAT 累积 2.5 s 时误差约 2–10°，但单帧精度随混响快速下降

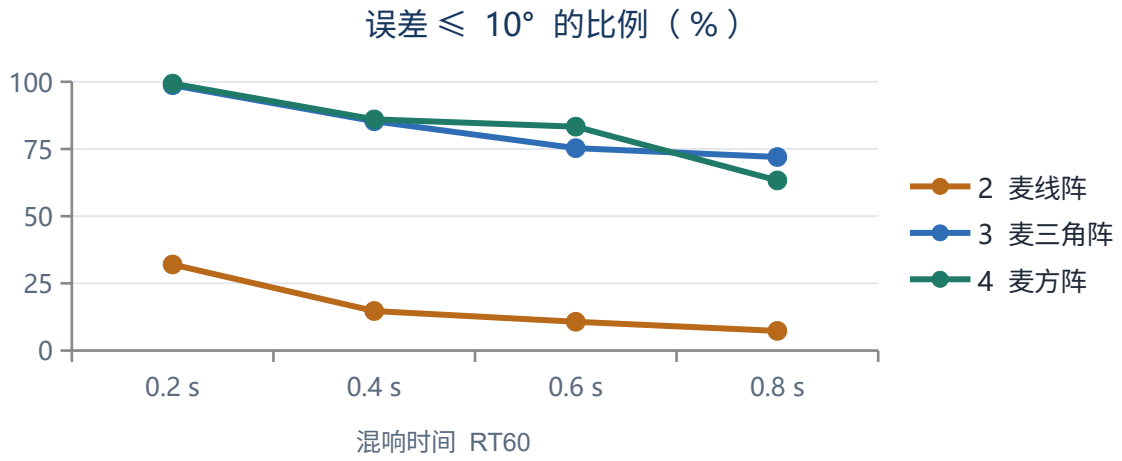
做法： 150 个随机房间 × 4 档混响；同孔径 5.7 cm 的 2 / 3 / 4 麦阵列； 2.5 s 中文语音；传感器噪声 SNR 15 dB； 300–4000 Hz、 1° 网格

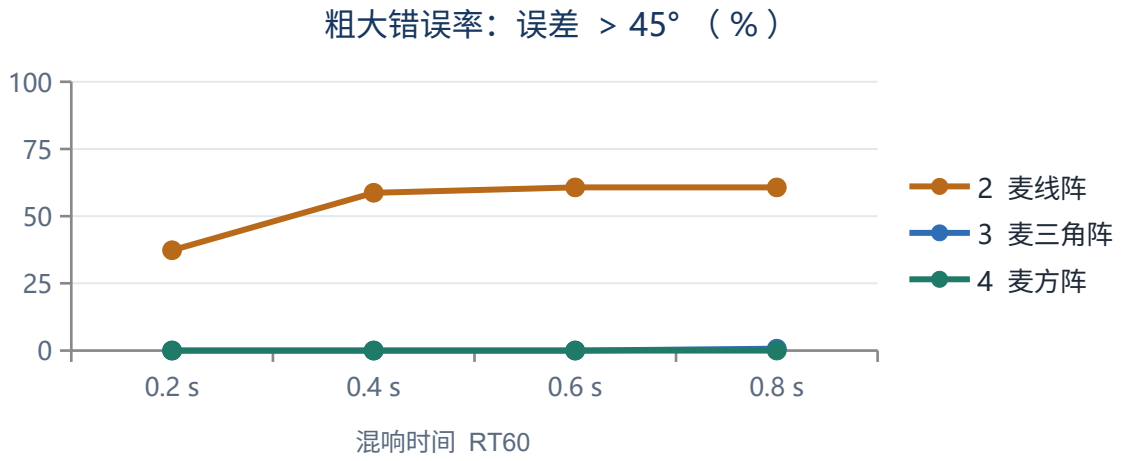


3 麦 ≈ 4 麦 ≫ 2 麦： 2 麦 37–61% 为镜像 / 粗大错误

单帧（32 ms）： 误差 ≤ 10° 的比例从 100% 降到 18%

结论： 难点在“短时间窗 + 混响”，这是 M1 要解决的核心





原型架构：唤醒触发 → 唤醒词片段测向 → 持续跟踪 → 方位同时驱动波束成形与云台

4 麦阵列
16 kHz； 2 s 环形缓存

→

语音唤醒（mentor）
输出唤醒词起止时间与置信度

→

特征提取
STFT 32 ms； PHAT 加权互谱（原型） / SALSA-Lite （Q1 网络）

→

测向
原型： SRP-PHAT + 起始段加权； Q1 ： 轻量网络

→

输出
每 100 ms ： 方位 + 置信度

↓

坐标变换
方位 + 云台编码器角 → 世界坐标

←

跟踪器
一期：圆周卡尔曼；三期：粒子滤波

←

转向决策
置信度确认、优先级、死区、干扰方向表

←

执行
云台转向 + 波束对准 → 视觉接管

电机状态：转动中冻结测向

视觉人形框：视听融合（三期）

唤醒词片段测向
唤醒词约 0.5–1 s 语音集中测向，不需要事件分类

给波束成形
方位 + 置信度；低置信度时保持上一方向（见下页）

原型算力【待定】
SRP-PHAT： 4 麦 6 对 × 119 频点 × 360 方向 / 帧；可降到 5° 网格

波束成形对测向的要求： ±10° 足够做延迟求和；小阵列难点在低频指向性，需要置信度配合

计算：延迟求和波束按估计方向对准、信号来自真实方向时的增益损失（ 300–4000 Hz 平均，孔径 5.7 cm ）





4 麦方阵延迟求和波束图： 1 kHz 几乎全向， 3 kHz 主瓣变窄， 6 kHz 出现栅瓣

测向够用： 4 麦误差 10° 仅损失约 0.1 dB， 20° 约 0.4 dB

真正瓶颈： 孔径小， 1 kHz 以下延迟求和几乎无指向性，需超指向 / MVDR 类方法

配合要求： 这类方法对方向误差更敏感（判断，待仿真验证），定位须给置信度，低置信度时保持方向或退回宽波束

对定位的要求 方位误差 ≤ 10° 、每 100 ms 更新、带置信度；波束成形算法本身的选型由负责人决定（分工待确认）。

持续跟踪：跟踪器维持航迹，状态机控制云台，避免抖动、误转与静音丢失

跟踪器	优点	局限	阶段
圆周卡尔曼（状态：方位 + 角速度）	轻量、平滑、易调参	单目标、单峰假设	**一期 ✓**
粒子滤波（以 SRP / 网络输出作似然）	可处理多峰与伪峰，便于视听融合	计算量随粒子数增长	**三期 ✓**
GM-PHD 等多目标滤波	多人同时说话	复杂度高	预研

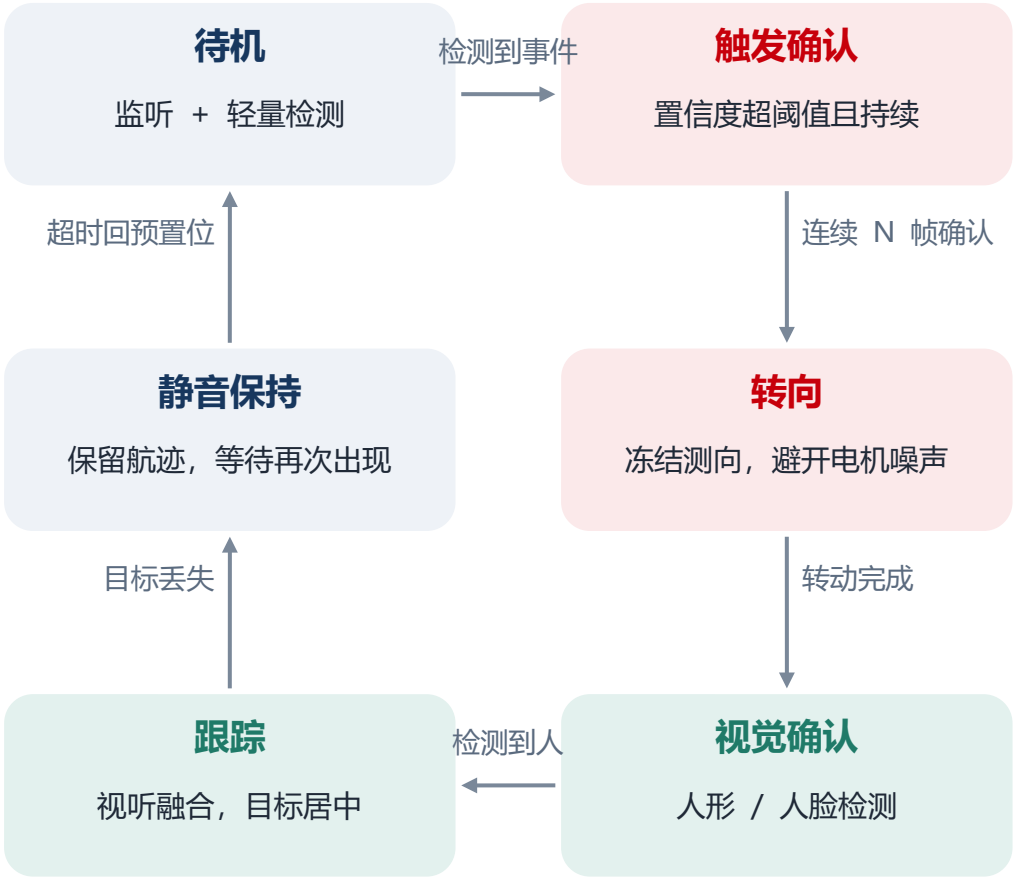
云台控制规则

确认：连续 N 帧置信度超过阈值才转，抑制瞬态误触发

死区：目标已在画面中央区域内不转，避免抖动

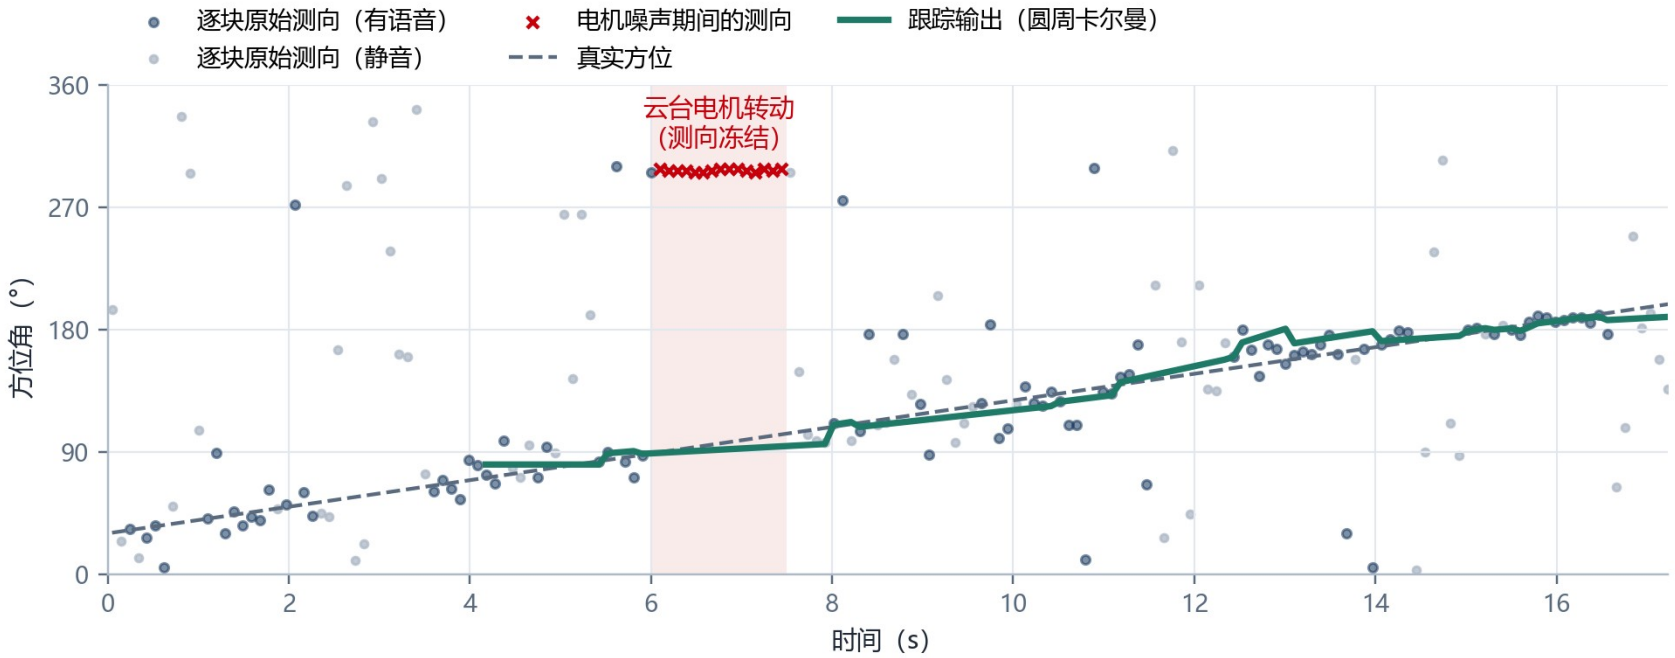
优先级：呼救 / 哭声 > 异常声 > 人声；同级按最近激活

干扰表：长时间固定方向、且视觉无人形的声源（如电视）记入干扰方向表



仿真示意：跟踪器把测向平均误差从约 22° 降到约 6°，电机转动时冻结测向避免被拉偏

做法： 4 麦方阵， RT60 = 0.5 s ； 说话人沿 2 m 圆弧从 30° 走到 200° （约 17 s ）； 6.0–7.5 s 叠加近场电机噪声（比语音高 6 dB ）



22° → 6°

平均误差：逐块原始测向 → 跟踪输出

14%

有语音时，原始测向中误差 > 45° 的比例

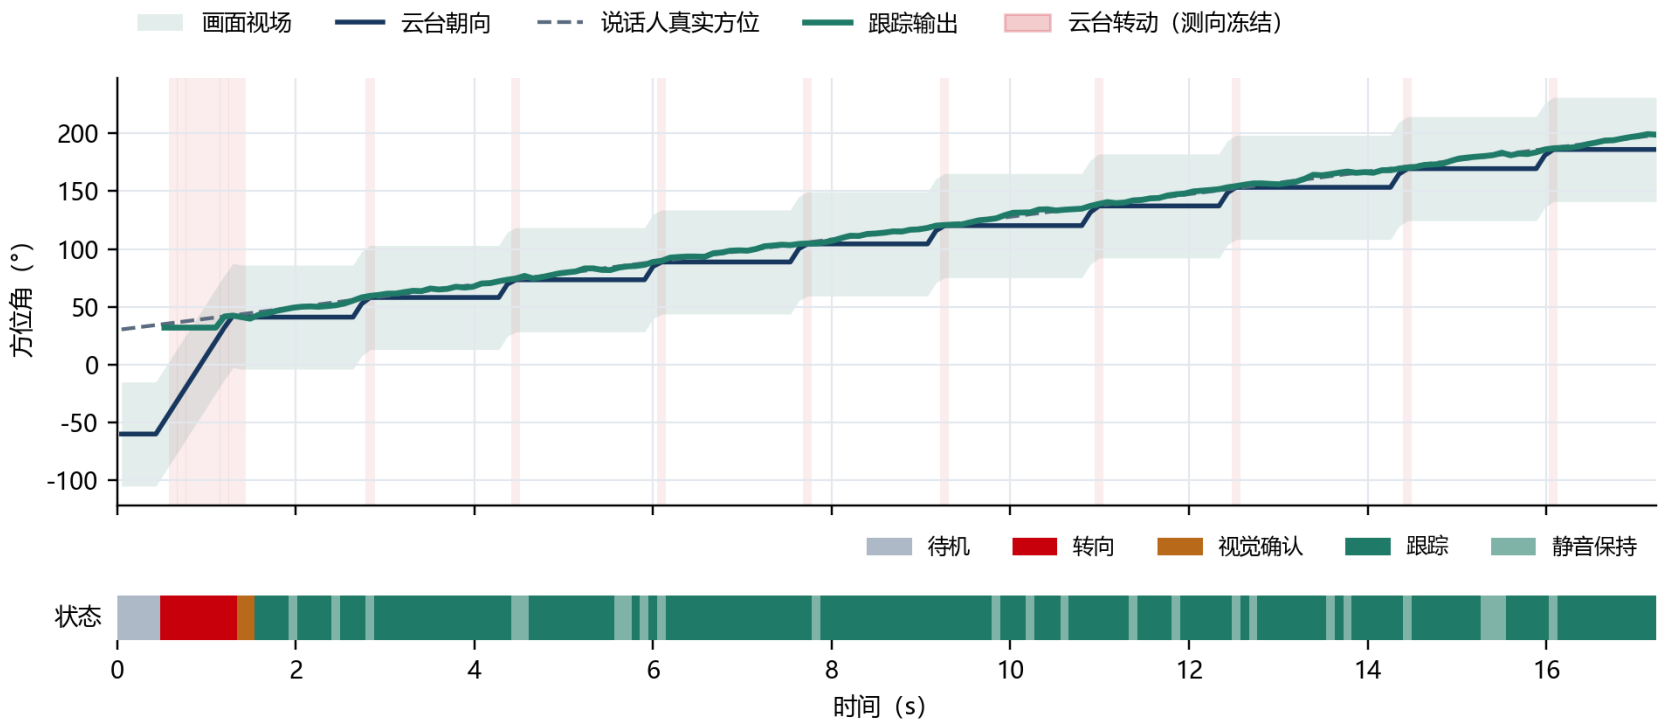
160°

电机转动期间原始测向的平均误差：不冻结就会被拉向电机

启示 单帧测向在混响下离散度很大，必须靠门控 + 跟踪 + 静音保持输出稳定方位；电机状态门控代价最低、收益最大。跟踪器参数未调优，属示意性结果。

闭环仿真：说话后 0.3 s 开始转向、 0.7 s 入画，之后目标 99% 时间位于画面中央一半

做法：基线 B0 全链路闭环；说话人在画面外开口并绕行 170°； RT60 = 0.5 s；视觉检测为模拟（画面内 90% 检出）



0.29 s

从触发到开始转动（目标 ≤ 0.5 s）

0.67 s

从触发到目标进入画面

98.8%

入画后目标位于画面中央一半的时间比例

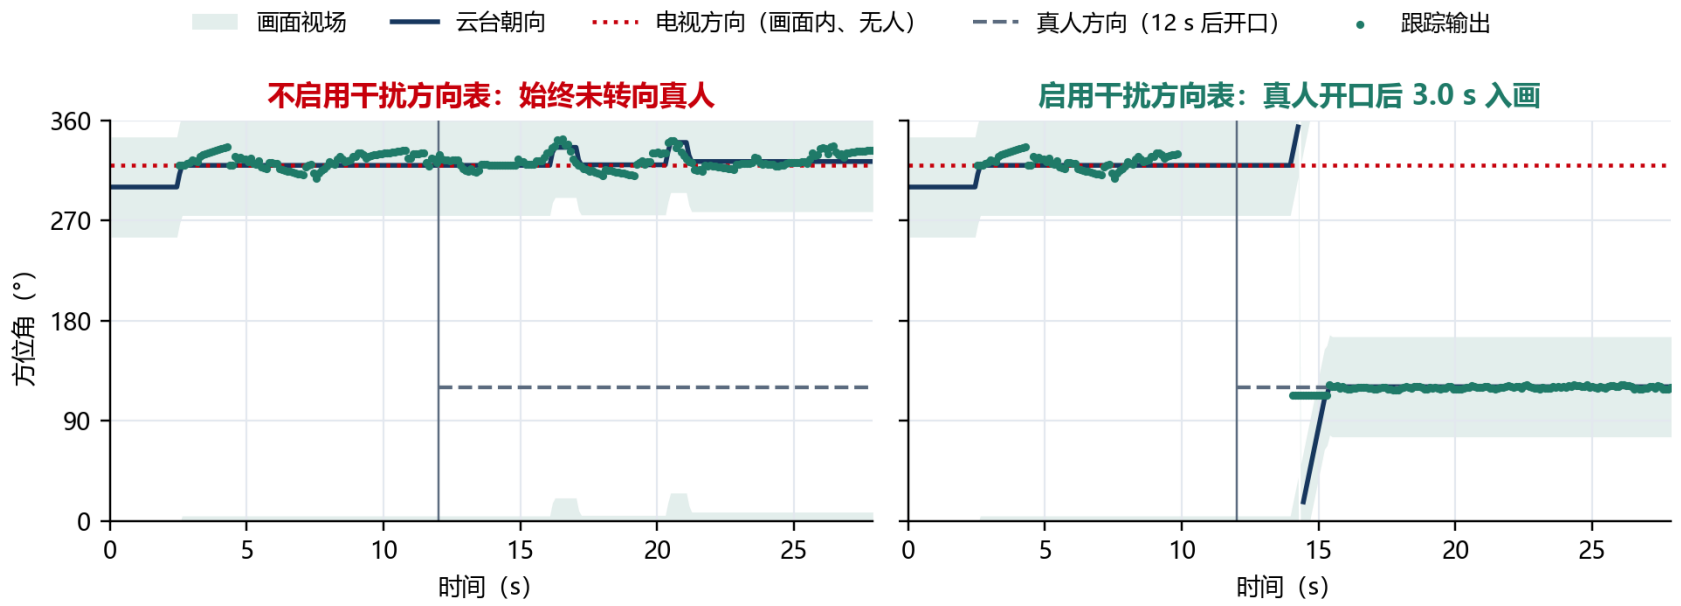
1.3°

融合视觉后的跟踪平均误差（17 s 内云台移动 10 次）

说明 死区设计让云台“走走停停”而不是持续抖动；单声源、无干扰、 RT60 = 0.5 s 的理想场景，视觉为模拟，真实效果需在设备上复测。代码见基线代码包。

电视干扰仿真：不启用干扰方向表时云台被电视“锁死”，启用后真人开口 3 s 内入画

做法：电视位于画面内、从 2 s 起持续播放人声（画面中无人）；真人 12 s 后在画面外 120° 处开口；其余设置同闭环仿真



不启用

跟踪器锁定电视；真人方向的观测被门控拒绝，云台始终不转

启用

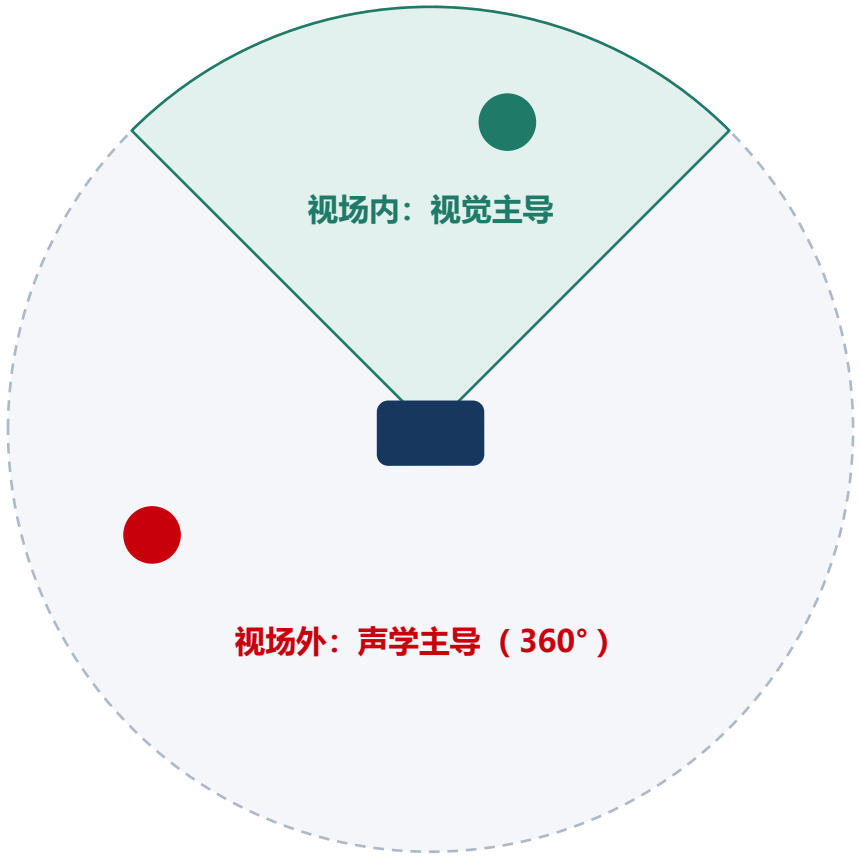
电视方向“有声无人”累计 4 s 后屏蔽 310–330°；真人开口 3.0 s 后入画，之后 81% 时间在画面内

解除

若之后在该方向看到真人，自动解除屏蔽，避免误伤

启示 电视误转是家用场景的头号风险，纯声学无法区分电视里的人声和真人；“画面内长时间有声无人”这一视觉线索代价很低、效果直接，应作为基线必备功能。屏蔽时长、解除条件需在真实家庭数据上调参。竞品中 Echo Show 10 采用让用户划定运动范围的方式处理类似问题。

视听融合：视场外靠声学找人，视场内由视觉精定位并确认谁在说话



1 坐标统一

像素横坐标 x 换算为方位： θ = θ 云台 + arctan((x − cx) / fx)，与声学方位在同一世界坐标下比对；麦克风阵列与摄像头需做一次外参标定

2 说话人确认

Light-ASD （CVPR 2023）：约 1.0 M 参数、 0.6 GFLOPs， AVA-ActiveSpeaker 上 mAP 94.1%；用于多人画面中判断谁在说话

3 融合跟踪

粒子滤波：声学方位似然 × 视觉检测似然；参考 AV3T / CAV3D （摄像头与麦阵共址）、 STNet （2024）

DCASE 2025 任务 3 新增“画面内 / 画面外”声源判定子任务，与本场景直接对应

前沿趋势：从“单点测向”走向视听联合、声学成像与空间音频大模型

按对本项目的可用时间排序：近期可用 → 中期储备 → 远期探索

近期可用

视听联合与画面内外判定

DCASE 2025 任务 3：双通道立体声 + 普通视角视频，新增画面内 / 外声源判定

启示：直接对应“声音在不在画面里、要不要转”

近期可用

真实数据与跨阵列泛化

RealMAN （NeurIPS 2024）：真实录音训练优于仿真，可训练可变阵列网络；Neural-SRP （2024）适配任意几何

启示：一套模型适配多款阵列硬件

近期可用

端侧轻量化

Cross3D-Edge： 127 MFLOPS，树莓派 4B 8.6 ms/ 帧；LightDOA （2025）用 LLM 辅助生成仿真声学场景

启示：常开端侧测向在算力上已可行

中期储备

从“点”到“图”：声学成像

DCASE 2026 任务 3 （6 月已结束，8 队 29 个提交）：只用 4 通道音频输出 1°/ 像素声能图；纯音频第一名 Mask mAP 仅 0.108

启示： 4 通道即可做，但精度尚低；可储备“画面叠加声源热力图”

远期探索

空间音频 + 大模型

BAT （ICML 2024）：空间音频编码器 + LLaMA-2 回答“在哪、是什么”； ELSA （NeurIPS 2024）空间音频 - 文本嵌入， 3D 定位误差约 15°

启示：支持“刚才玻璃碎的声音在哪”之类的语义查询

公开数据集：按与场景的贴近程度选用，真实数据用于微调与评测

数据集（出处）	采集方式与阵列	动态声源	视频	规模	许可	本方案用途
CAV3D （FBK， IEEE TMM 2019）	真实； 8 麦圆阵与摄像头共址	✓	✓	20 段序列（单人 / 干扰 / 多人）	见官网	**视听跟踪评测（最贴近）**
RealMAN （NeurIPS 2024）	真实； 32 麦阵列，可抽子阵模拟产品几何	✓ 35 h	—	83 h 语音 + 144 h 噪声，32 个场景	CC BY 4.0	**真实微调与评测、真实噪声**
SSLR （Idiap， ICRA 2018）	真实； Pepper 机器人头 4 麦（5.8 × 6.9 cm），含风扇自噪声	部分	—	约 25 h 回放 + 真人录音	EULA 非商用	**小孔径 + 自噪声测向评测**
LOCATA （IEEE/ACM TASLP 2020）	真实； 4 类阵列（含 12 麦机器人头、助听器）	✓ 含移动阵列	—	6 个任务（静 / 动声源 × 静 / 动阵列）	Open Data Commons	跟踪评测（移动阵列 ≈ 云台转动）
STARSS23 （DCASE 2023）	真实； 4 通道四面体阵列（MIC）/ FOA	✓	360°	168 段约 7.5 h， 16 个房间，13 类	MIT	事件 + 定位联合评测
DCASE2025 立体声 SELD	由 STARSS23 转换：双通道 + 普通视角视频	✓	✓	13 类，含画面内 / 外标签	见 Zenodo	2 麦 + 有限视场参照
AV16.3 （Idiap， 2004）	真实； 2 组 8 麦圆阵 + 3 台摄像头	✓	✓	43 段	EULA 非商用	视听跟踪经典对比

非商用许可的数据仅用于研究对比，产品训练使用商用友好数据与自采数据。前沿： DCASE 2026 任务 3 转向“声学成像”（STAIRS26， 32 通道），可作为画面叠加声源热力图的参考。

数据方案：按产品阵列几何大规模仿真，真实数据微调，自采数据闭环验收

1 仿真训练集（主体）

工具： gpuRIR（支持移动轨迹）、pyroomacoustics、SpatialScaper

房间： 边长 3–8 m，RT60 0.2–0.9 s

声源： 距离 0.5–5 m，方位 0–360°；静止 / 直线 / 随机游走

干扰： 扩散噪声 + 定向干扰（电视、音乐），SNR −5 ~ 20 dB，1–3 个声源重叠

增强： 阵元位置扰动、通道增益与相位失配、对称阵列通道置换

素材： AISHELL-1、LibriSpeech、FSD50K（按许可筛选）；噪声 DEMAND、MUSAN

2 真实数据（微调与评测）

RealMAN： 抽取与产品几何最接近的子阵；真实语音 + 真实噪声

公开对比： LOCATA、STARSS23、CAV3D

流程： 仿真预训练 → 真实数据微调 → 同矩阵评测

3 自采数据（验收依据）

设备实录： 3–5 类房间 × 8 个方位 × 3 个距离 × 4 种干扰（安静 / 电视 / 空调 / 电机转动）

声源： 真人 + 音箱回放

标注： 摄像头自动检测或转台

误转专测： 长时无人录音（含电视）

评测分三层：帧级测向、轨迹跟踪、系统体验，各方案在同一测试矩阵上对比

1 帧级测向

- 方位平均绝对误差（MAE）
- Acc@10° / Acc@20°
- 粗大错误率（误差 > 45°）
- SELD 联合指标：F1@20°、LE_CD、LR_CD（DCASE）

2 轨迹跟踪

- 轨迹平均误差
- 航迹断裂与丢失率
- 多人场景 ID 切换次数
- 参考 LOCATA 评测体系

3 系统体验

- 转向命中率
- 响应时延
- 误转率（次 / 小时）
- CPU / NPU 占用、内存、功耗

统一测试矩阵

RT60：0.3 / 0.6 / 0.9 s × SNR：20 / 10 / 0 dB × 声源数：1 / 2 × 声源：静止 / 移动 × 电机：静止 / 转动

仿真与自采数据均按此矩阵出结果，B0 / M1 / E1 逐格对比，用数据决定是否进入下一阶段。

先做 demo：离线回放保底、实时演示加分，每周用同一组场景展示进展

演示场景固定，每周只换算法版本，进展一目了然

A 离线回放 demo （11 月第 2 周起每周可演示）

- 输入：多通道录音（仿真 / 公开数据 / 实录） + 唤醒时间戳
- 流程：唤醒词片段测向 → 持续跟踪 → 云台状态机
- 展示：方位随时间曲线、俯视图上的说话人与云台指向
- 输出：每个场景的误差、时延统计

B 实时 demo （12 月中旬）

- 硬件：目标阵列或 4 麦 USB 阵列 + PC【待确认】
- 流程：实时采集 → 唤醒（mentor 模块，或先用按键模拟）→ 方位显示
- 展示：虚拟 / 真实云台转向；波束成形前后的音频对比（可选）
- 输出：演示视频 + 实测时延

固定演示场景

① 正前方唤醒　② 侧后方唤醒（考察 360°）　③ 唤醒后边说边走　④ 电视开着时唤醒　⑤ 两人先后唤醒

每个场景记录：方位误差、定向时延、是否转对（目标进画面中央一半）、误转次数

12 月底原型计划：11 月每周 2 天做离线验证，12 月全职做实时 demo 与集成

按实际投入约 28 个工作日（11 月 6 天、12 月约 22 天，12/25 假期）；每周与 mentor 讨论一次

周	日期	投入	目标	周会交付
W1	11/09–11/15	2 天	对齐接口、demo 硬件与验收指标；代码改成“唤醒词片段测向”接口	接口约定 v1
W2	11/16–11/22	2 天	离线 demo A v0：仿真 + 公开数据（LOCATA）	离线 demo；首版误差表
W3	11/23–11/29	2 天	录音方案与录音脚本；若阵列已到，先录一小批	录音方案 + 首批实录
W4	11/30–12/06	**全职**	实录评测与调参；唤醒后持续跟踪	实录评测表
W5	12/07–12/13	**全职**	实时流式框架 + 方位显示（虚拟云台）	实时运行；时延实测
W6	12/14–12/20	**全职**	接入唤醒（或按键模拟） + 波束成形接口；端到端 demo	实时 demo B 视频
W7	12/21–12/27	**全职 4 天**	鲁棒性：电视、强混响、两人场景；算力估计	鲁棒性评测表
W8	12/28–12/31	**全职 4 天**	原型冻结、报告与演示；Q1 计划	原型代码 + 报告 + demo

主要风险与预案 阵列未到位 → 先用通用 4 麦 USB 阵列；唤醒接口未就绪 → 先用录音时间戳 / 按键模拟；电视误唤醒 → 干扰方向表 + 视觉复核。

首次周会要对齐的六件事：硬件、唤醒接口、波束成形分工决定原型细节

1 阵列与 demo 硬件

麦克风数量、间距、安装位置？ demo 用哪块板或阵列？

2 唤醒接口

唤醒跑在单通道还是多波束？能否给出唤醒词起止时间与置信度？

3 波束成形

由谁负责？需要定位输出什么（方位、置信度、更新率）？

4 芯片预算

目标 SoC 的算力、内存与常开功耗预算？

5 镜头与云台

水平视场角、云台转速、电机噪声水平？

6 数据与周会

能否录设备实录？每周讨论的时间与形式？