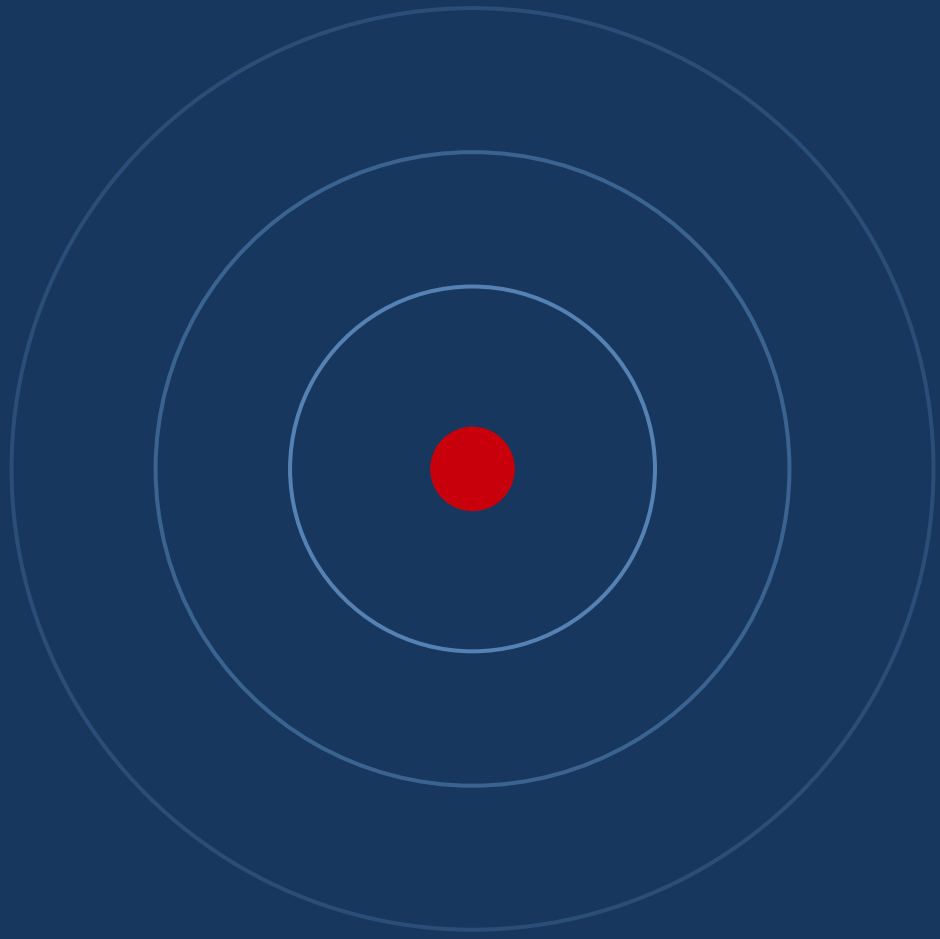
声源定位（SSL）调研 · 场景一

摄像头声源定位与持续跟踪

需求拆解 · 方案选型 · 数据集 · 原型路线



汇报人：令狐雅熙　2026.11

12 月原型建议：先做唤醒后声源定位与持续跟踪 demo

首轮以 SRP-PHAT 为测向基线，对比有无起始段加权，再接入圆周卡尔曼跟踪；方位与置信度同时供波束成形和云台使用

首选方案

- 唤醒后从环形缓存取唤醒词片段测向： SRP-PHAT 基线，起始段加权作对照
- 唤醒前已存在的干扰（电视）：用唤醒前背景白化（ GEVD-MUSIC ）作为候选，与基线同表对比
- 之后圆周卡尔曼持续跟踪；云台状态机负责确认、死区、转动时冻结测向

当前进展

- 仿真已完成静态测向、移动跟踪、模拟云台闭环、电视干扰、唤醒词定向五组实验；下一步用实际唤醒词与真实录音验证
- 唤醒词片段 + 持续电视干扰（ RT60 0.6 s 、 SIR 0 dB ）： 10° 内命中率 SRP-PHAT + 起始段加权 35% ， GEVD-MUSIC 63% ；同一 MUSIC 去掉背景白化为 36%

首轮数据

- LOCATA： Task 1 静态测向、 Task 3 移动说话人跟踪
- 带唤醒词起止样点与方位真值的多通道音频：测首次定向精度与输出时延

请确认

1. **原型阵列与板卡**
   麦克风数量、间距、安装位置
2. **唤醒模块可提供的时间信息**
   唤醒词起止样点、置信度、回调延迟
3. **波束成形需要的定位输出**
   方位、置信度、更新率

后续方向（视原型结果再定） 轻量神经网络纯测向，提升短时间窗 + 混响下的精度；视听融合与异响事件触发

场景一闭环：唤醒 → 定向 → 转向与波束对准 → 视觉接管 → 持续跟踪



声学主导　唤醒、定向、波束对准：误差只要让目标进入画面中央即可

视觉主导　视场内精定位、确认是谁在说话

已有先例：华为智选海雀雀蛋 Pro“海雀海雀”唤醒后转向（双麦，2025）；Amazon Echo Show 10 唤醒词转屏（已停产）；萤石 C6C 3 麦声源定位

模块与接口：唤醒给“何时”，定位给“在哪”，波束成形与云台按方位执行

下表为建议格式，状态列标出待确认项；格式可随唤醒模块调整

麦克风阵列
16 kHz； 3 s 环形缓存 → **语音唤醒**
检测唤醒词 → 起止时间、置信度 → **声源定位**
唤醒词片段测向 + 持续跟踪 → **波束成形**
按方位增强说话人语音 → **云台与视觉**
转向、视觉确认、居中

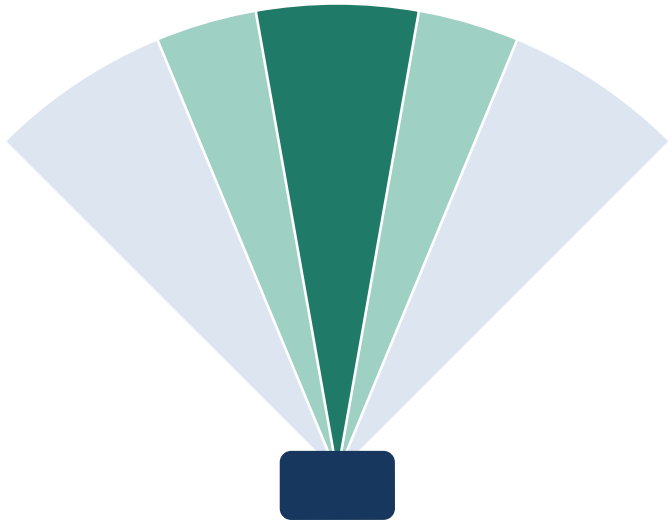
接口	内容	建议格式	状态
阵列 → 各模块	麦克风数量、几何、采样率、帧长、缓存长度	16 kHz；帧 16 ms；环形缓存 3 s （含唤醒词前约 1 s 背景）	**待确认**
唤醒 → 定位	触发时刻、唤醒词起止样点、置信度；唤醒跑在哪个通道 / 波束	回调或消息；样点级时间戳；实测分别记录词尾→回调、回调→输出	**待确认**
定位 → 波束成形	方位（俯仰可选）、置信度、更新时刻	每 100 ms；低置信度时保持上一方向	**待确认**
定位 → 云台	设备固定坐标系方位、是否转动；读取云台角与电机状态	状态机输出（死区、确认、冻结）	**仿真已跑通 实机接口待确认**

设计选择 唤醒若跑在多个固定波束上，可直接用得分最高的波束作粗方向；但 Amazon 指出波束选择不适合直接驱动转动，所以建议“先唤醒、再用唤醒词片段精确测向”。

精度要求由镜头视场反推：方位误差小于 HFOV/4 ，目标即落在画面中央一半

允许误差 ⩽ HFOV / 4

转向后目标落在画面中央一半，就能交给视觉精对准。以 HFOV = 90° 为例，允许 ±22.5°；取 ±10° 作设计目标，为人员移动和跟踪延迟留余量。



水平视场 HFOV = 90°（示例）
中央一半： ±22.5°
设计目标： ±10°

建议指标（目标值待与产品需求对齐；时延从唤醒词结束计时）

指标	定义	建议目标
方位误差	单声源、 RT60 ⩽ 0.6 s 、 SNR ⩾ 10 dB 下的平均绝对误差	⩽ 10°
转向命中率	转动结束后目标位于画面中央一半的比例	⩾ 90%
粗大错误率	误差 > 45°（含前后混淆）的比例	⩽ 3%
定向 / 转向时延	唤醒词结束 → 输出方位 / 云台开始转动；含唤醒回调延迟	⩽ 0.1 s / ⩽ 0.5 s【待确认】
误转率	无有效唤醒时的转动次数（含电视误唤醒）	⩽ 1 次 / 小时
端侧开销	常开链路的算力、内存与功耗	【待定】

后文仿真结果为当前进展，计时起点与条件各页单独注明，不直接对应本页目标。

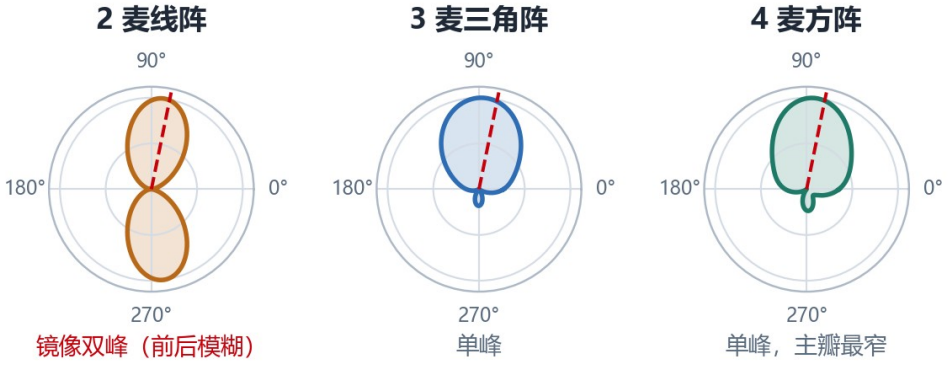
五个工程难点决定方案取舍：小孔径、混响干扰、电机自噪声、间歇多源、常开功耗

难点	对测向的影响	对策（对应模块）
1　小孔径、少阵元（2–4 麦，3–6 cm）	低频角分辨率差；间距 4 cm 时约 4.3 kHz 以上出现空间混叠；2 麦线阵前后对称，只能测 0–180°	≥ 3 麦平面阵；空间特征限定在混叠频率以下；2 麦方案借云台小角度转动消除前后模糊
2　室内混响与定向干扰（电视、音箱）	墙面反射产生伪峰；电视里的人声触发误转	PHAT 加权 + 起始段加权；唤醒前背景白化（GEVD-MUSIC）；干扰方向表 + 视觉复核（无人形不跟）
3　云台电机自噪声，阵列可能随云台转动	转动时测向失真；阵列随云台转时坐标系随转角变化	电机状态门控（转动期间冻结测向）；阵列随云台转时用云台角换算到设备固定坐标系；后续做电机噪声模板抑制
4　声源间歇、移动、多人同时说话	说话停顿即丢目标；多人时不确定转向谁	跟踪器静音保持；事件优先级 + 最近激活策略；多目标跟踪预研
5　常开低功耗	网络全时运行功耗高	两级触发：轻量检测常开，确认后再唤醒测向网络

注：空间混叠频率 $f = c / 2d$（$c \approx 343$ m/s，d 为阵元间距）

阵列构型：仿真以 4 麦平面阵为候选配置，3 麦单声源精度接近；2 麦需借云台转动消歧

	2 麦线阵	3 麦三角阵	4 麦方阵 / 圆阵
方位覆盖	0–180°（前后对称）	0–360°	0–360°
同时声源数（子空间法上限 M−1）	1	2	3
俯仰角	不可测	可测，上下对称	可测，上下对称
适配算法	GCC-PHAT、LightDOA	SRP-PHAT、神经网络	SRP-PHAT、MUSIC、4 通道 SALSA-Lite
成本	最低	中	中高
结论	低成本档，需主动消歧	可用：单声源精度接近 4 麦	**当前仿真配置（候选）**



仿真：同一声源（RT60 = 0.4 s）的 SRP-PHAT 空间谱，红色虚线为真实方向。旁证：双麦的雀蛋 Pro 评测称“正面 180° 内识别”

安装位置：两种条件

固定在底座：声学方位已在设备固定坐标系，转向量 = 目标方位 − 云台角；当前闭环仿真采用此方式

随云台转动：阵列局部方位须加云台角换到固定坐标系；转动中相当于“移动阵列”（LOCATA 移动阵列任务）

孔径取舍：孔径越大角分辨率越好，但混叠频率越低（d = 5 cm 时约 3.4 kHz）；建议 5–6 cm

【待确认】产品阵元数、间距与安装位置

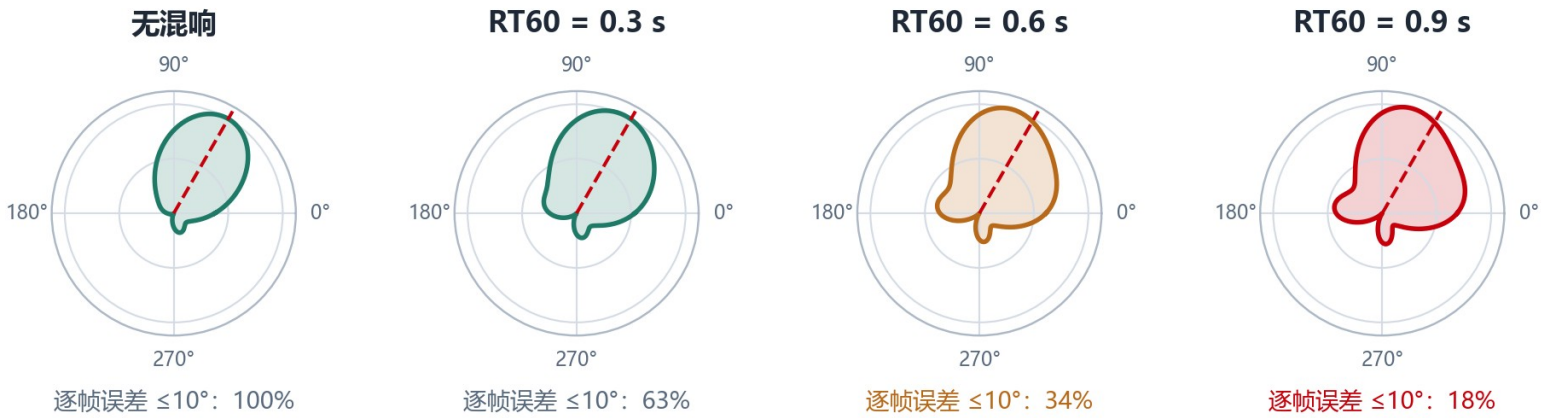
测向算法选型： SRP-PHAT 为首轮基线，起始段加权为对照变量；唤醒前背景白化作抗干扰候选

方法（出处）	原理	混响 / 噪声鲁棒	多声源	事件类别	端侧开销	定位
GCC-PHAT	麦克风对时延估计	**中**	弱	无	极低	2 麦方案组件
SRP-PHAT （ pyroomacoustics 可复现）	扫描方位网格上各麦克风对的 PHAT 能量（本次实验 1° 网格； 5° 为待验证的降算力配置）	**中**	**中**	无	低	**12 月原型基线**
GEVD-MUSIC （ IROS 2009； HARK 实现）	用唤醒前背景协方差白化唤醒词片段，再做子空间扫描	**强（唤醒前已有的干扰）**	**中**	无	中（唤醒时算一次）	**唤醒词定向候选**
MUSIC	子空间谱估计	弱（相干反射）	**强**	无	中	对照
Cross3D-Edge （ ACM TECS 2023 ）	SRP 功率图 + 裁剪后的 3D CNN	**强**	单声源	无	树莓派 4B 8.6 ms/ 帧	后续纯测向候选
LightDOA （ arXiv 2025 ）	双通道 IPD + 轻量卷积 + GRU， 0–180°	**中**	弱	无	低	2 麦方案备选
FN-SSL / IPDnet （ Interspeech 2023/2024 ）	全带 - 窄带融合估计直达声 IPD	**强**	**强（ IPDnet ）**	无	较高	精度参照 / 教师模型
轻量 SELD （ SALSA-Lite + CRNN + Multi-ACCDOA ）	逐帧输出“类别 × 方向向量”	**强**	**强**	**有**	中，可裁剪	异响扩展

首轮比较： SRP-PHAT 有 / 无起始段加权 → 接入跟踪器；唤醒词定向另比 GEVD-MUSIC 。唤醒已判断“是不是人声”，后续网络先做纯测向， SELD 留给异响扩展。评级综合各论文报告与原理分析，以统一测试矩阵复测为准。

初步仿真： 3/4 麦累积 2.5 s 时误差约 2–10°； 1 s 片段下起始段加权明显降低误差

做法： 150 个随机房间 × 4 档混响；同孔径 5.7 cm 的 2 / 3 / 4 麦阵列； 2.5 s 中文语音； SNR 15 dB； 300–4000 Hz、 1° 网格（本次实验配置）

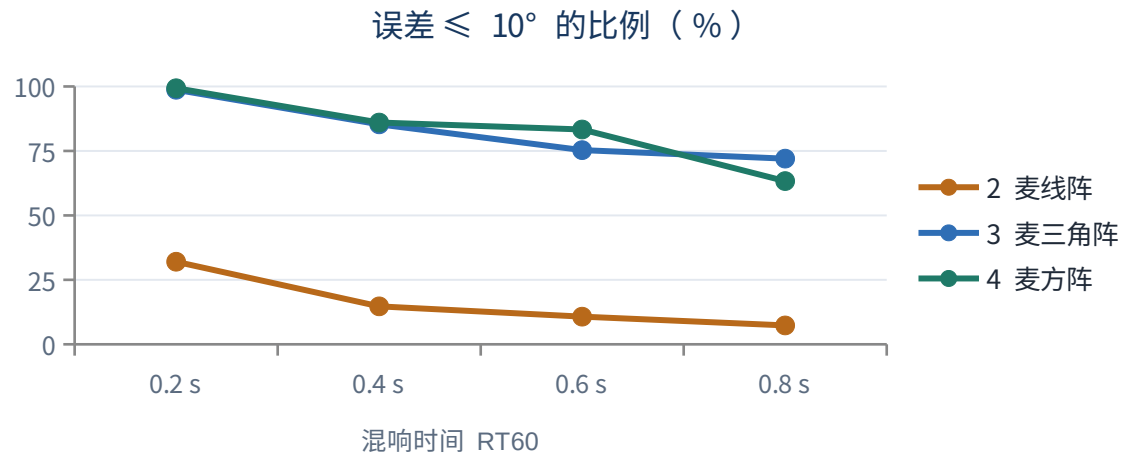


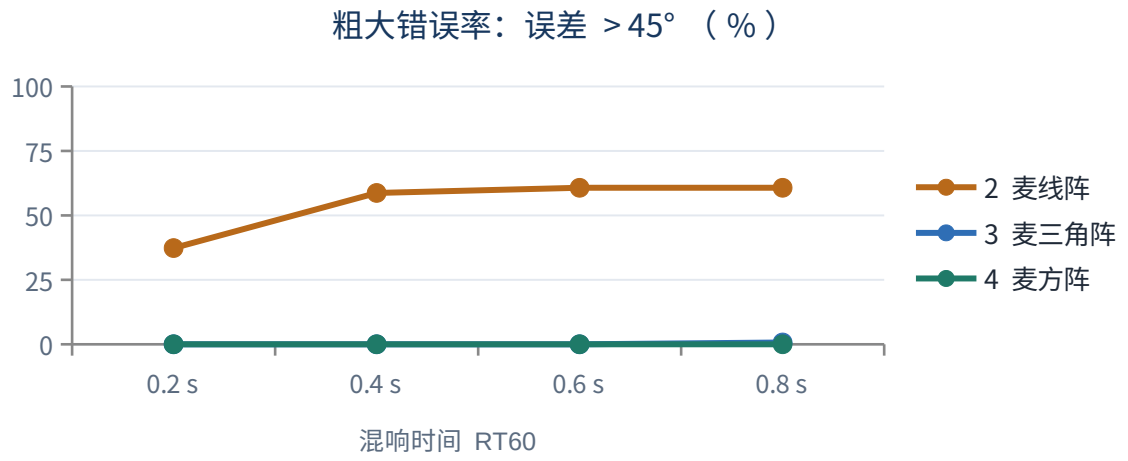
3 麦 ≈ 4 麦 ≫ 2 麦： 2 麦 37–61% 为镜像 / 粗大错误

单帧（32 ms）： 误差 ⩽ 10° 的比例从 100% 降到 18%

1 s 片段（接近唤醒词）： 4 麦、 RT60 0.8 s，起始段加权使平均误差 12.9° → 8.5°， 10° 内命中 54% → 69%

下一步： 用实际唤醒词片段复测

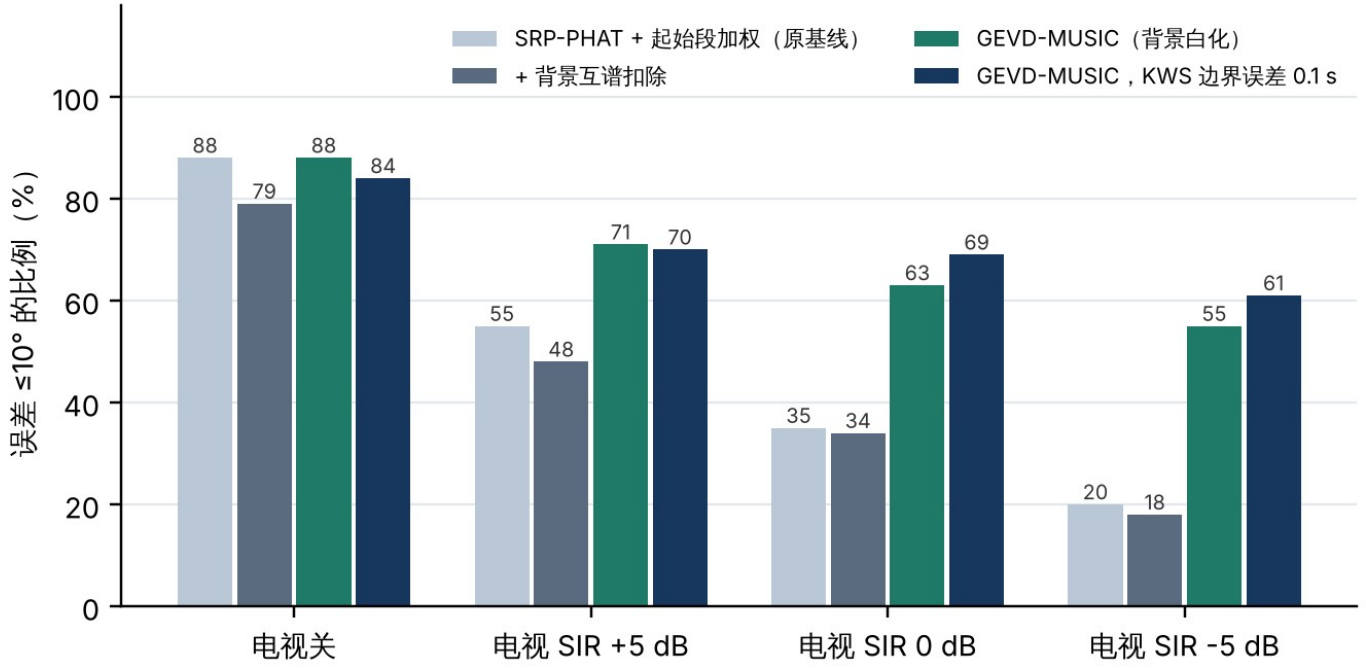




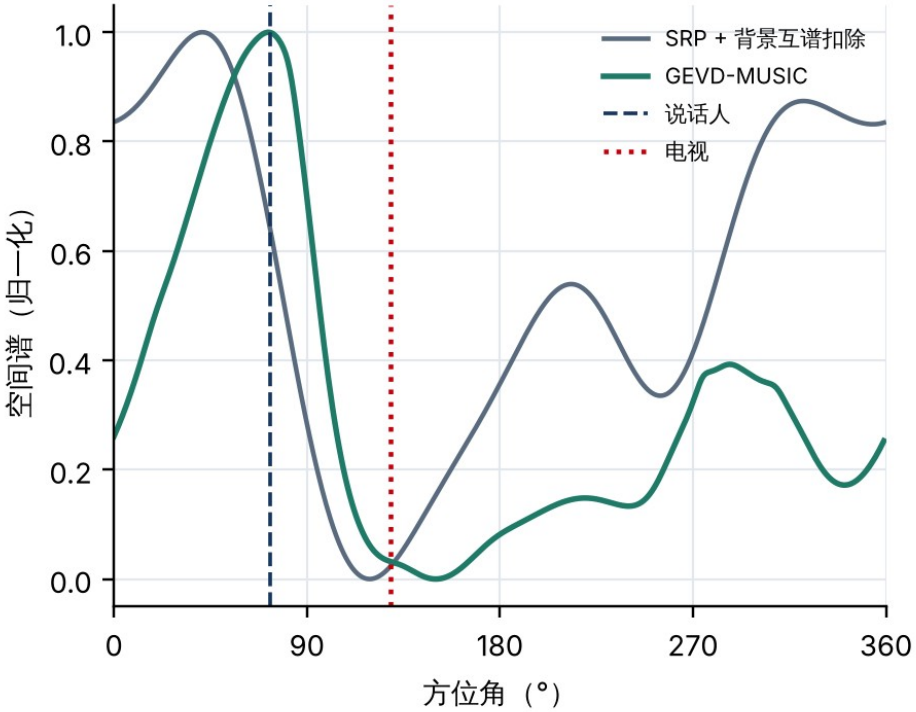
唤醒词定向仿真：持续电视干扰下 10° 内命中， GEVD-MUSIC 63% ， SRP-PHAT 基线 35%

做法：每档混响 100 个随机房间； 1 s 普通话片段模拟唤醒词；电视持续播放、与说话人相隔 ≥ 45° ； 4 麦 5.7 cm ； SNR 20 dB ；图中比例为 RT60 0.6 s

唤醒词定向精度（仿真，**RT60 0.6 s**，**1 s** 唤醒词，**4 麦 5.7 cm**）



示例：电视 **SIR 0 dB** 时的空间谱

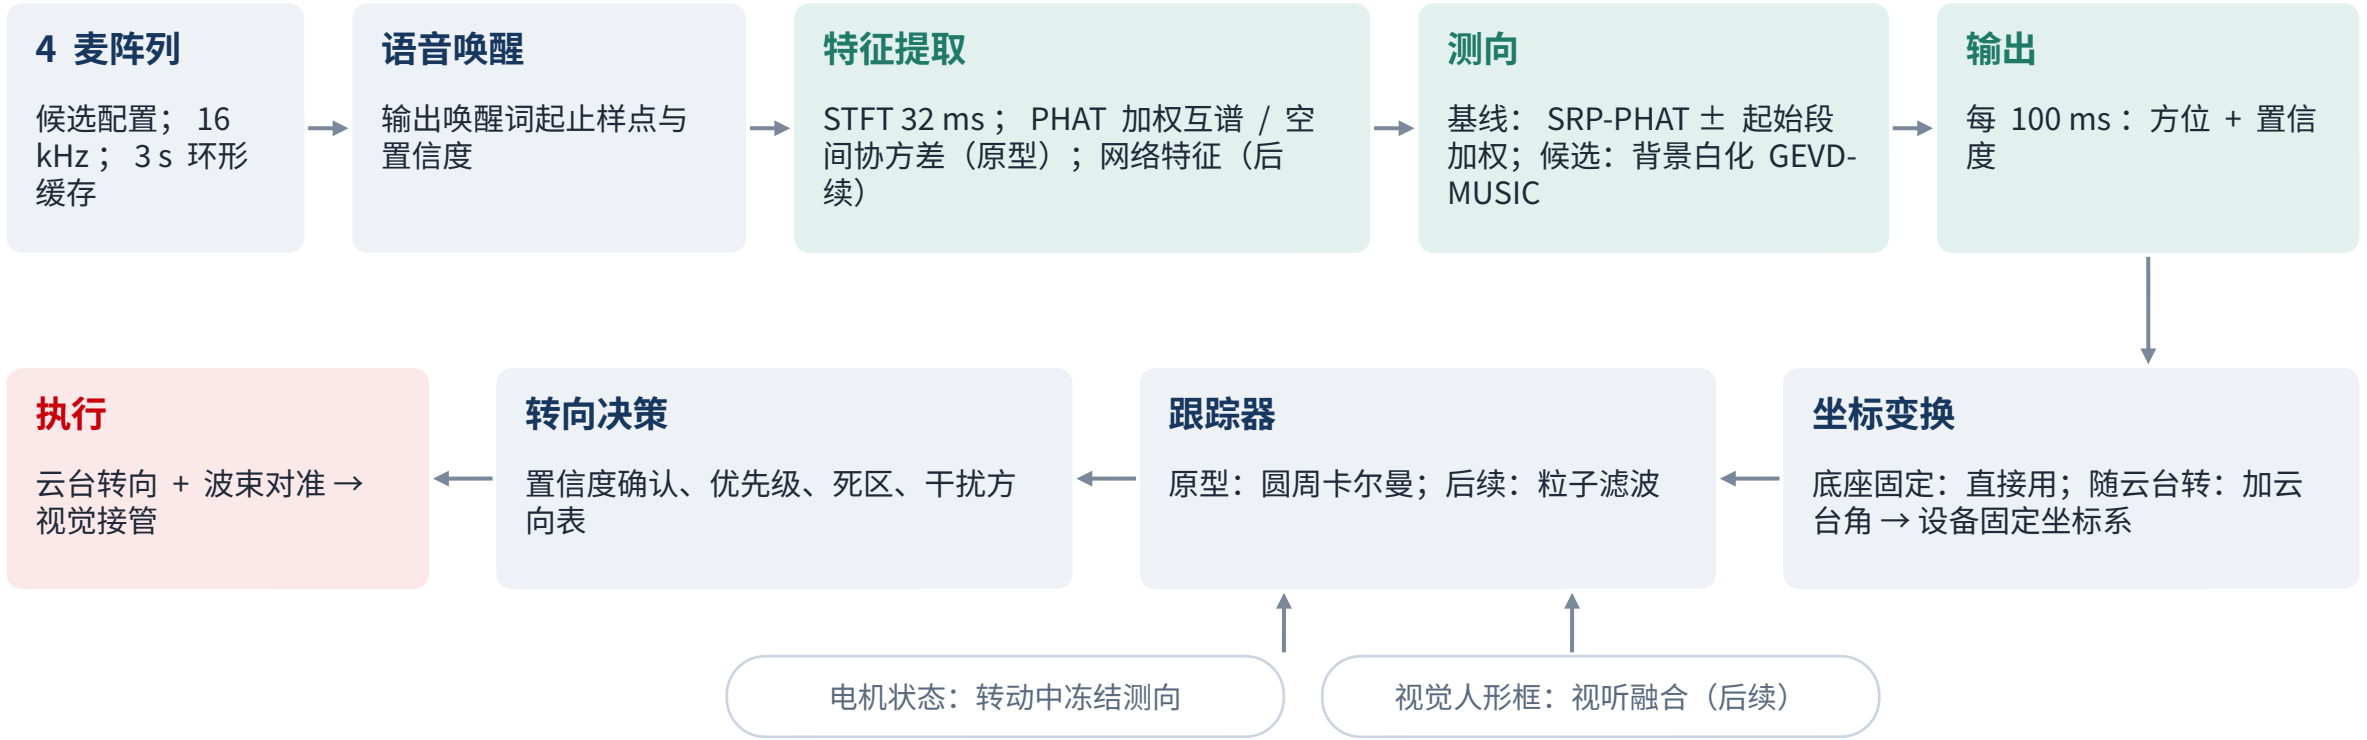


消融 同一 MUSIC 实现（RT60 0.6 s 、 SIR 0 dB ）：无背景白化 36% ，有白化 63% 。白化用唤醒词前约 1 s 的背景（电视 + 噪声）估计空间协方差

结果 电视关时与基线持平（ 88% ）； SIR −5 dB 时 20% vs 55% ；起止点误差 0.1 s 、不多取词尾后音频，精度均无明显变化；置信度最高的三分之一中 93% 在 10° 内

局限 要求唤醒前用户未说话；人与电视方位相近（ < 45° ）未评测；仿真为鞋盒房间，下一轮用实际唤醒词录音复测

原型架构：唤醒触发 → 唤醒词片段测向 → 持续跟踪 → 方位同时驱动波束成形与云台



唤醒词片段测向

唤醒词约 0.5–1 s 集中测向；唤醒前约 1 s 背景用于抑制干扰；当前多取词尾后 0.1 s，可去掉以降时延

给波束成形

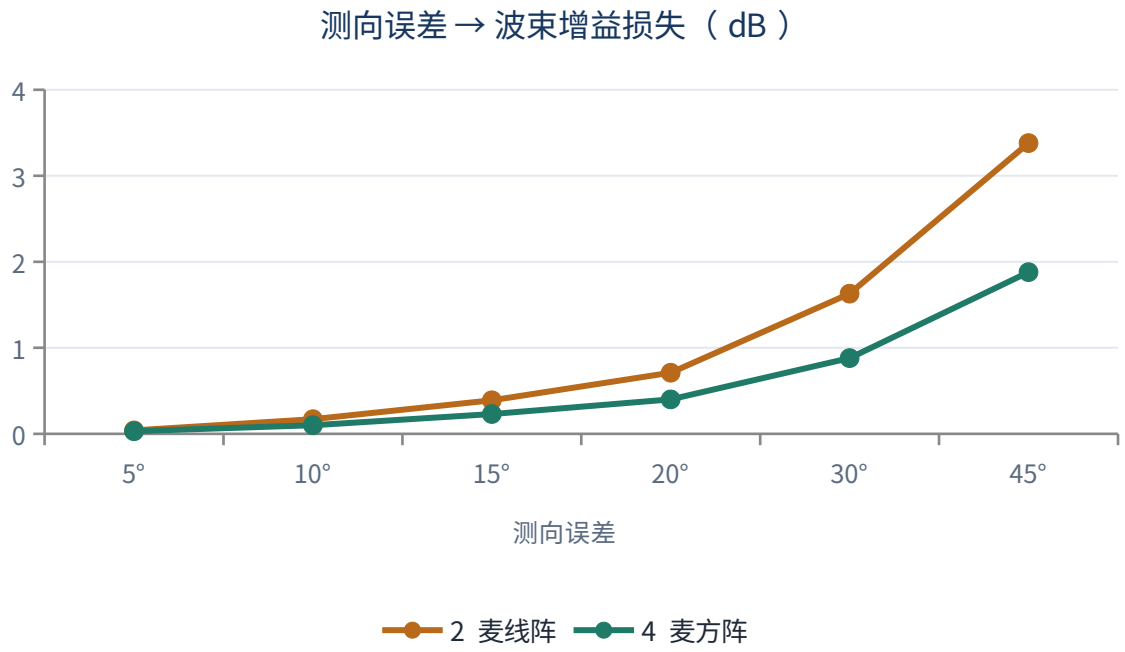
方位 + 置信度；低置信度时保持上一方向（见下页）

原型算力【待定】

本次实验 1° 网格（360 方向）； 5° 网格（72 方向）为待验证的降算力配置

波束成形对测向的要求： ±10° 足够做延迟求和；小阵列难点在低频指向性，需要置信度配合

计算：延迟求和波束按估计方向对准、信号来自真实方向时的增益损失（ 300–4000 Hz 平均，孔径 5.7 cm ）





4 麦方阵延迟求和波束图： 1 kHz 几乎全向， 3 kHz 主瓣变窄， 6 kHz 出现栅瓣

测向够用： 4 麦误差 10° 仅损失约 0.1 dB ， 20° 约 0.4 dB

真正瓶颈： 孔径小， 1 kHz 以下延迟求和几乎无指向性，需超指向 / MVDR 类方法

配合要求： 这类方法对方向误差更敏感（判断，待仿真验证），定位须给置信度，低置信度时保持方向或退回宽波束

对定位的要求 方位误差 ⩽ 10° 、每 100 ms 更新、带置信度；波束成形算法另行选型，定位侧按此接口输出。

持续跟踪：跟踪器维持航迹，状态机控制云台，避免抖动、误转与静音丢失

跟踪器	优点	局限	阶段
圆周卡尔曼（状态：方位 + 角速度）	轻量、平滑、易调参	单目标、单峰假设	**原型 ✓**
粒子滤波（以 SRP / 网络输出作似然）	可处理多峰与伪峰，便于视听融合	计算量随粒子数增长	**后续**
GM-PHD 等多目标滤波	多人同时说话	复杂度高	预研

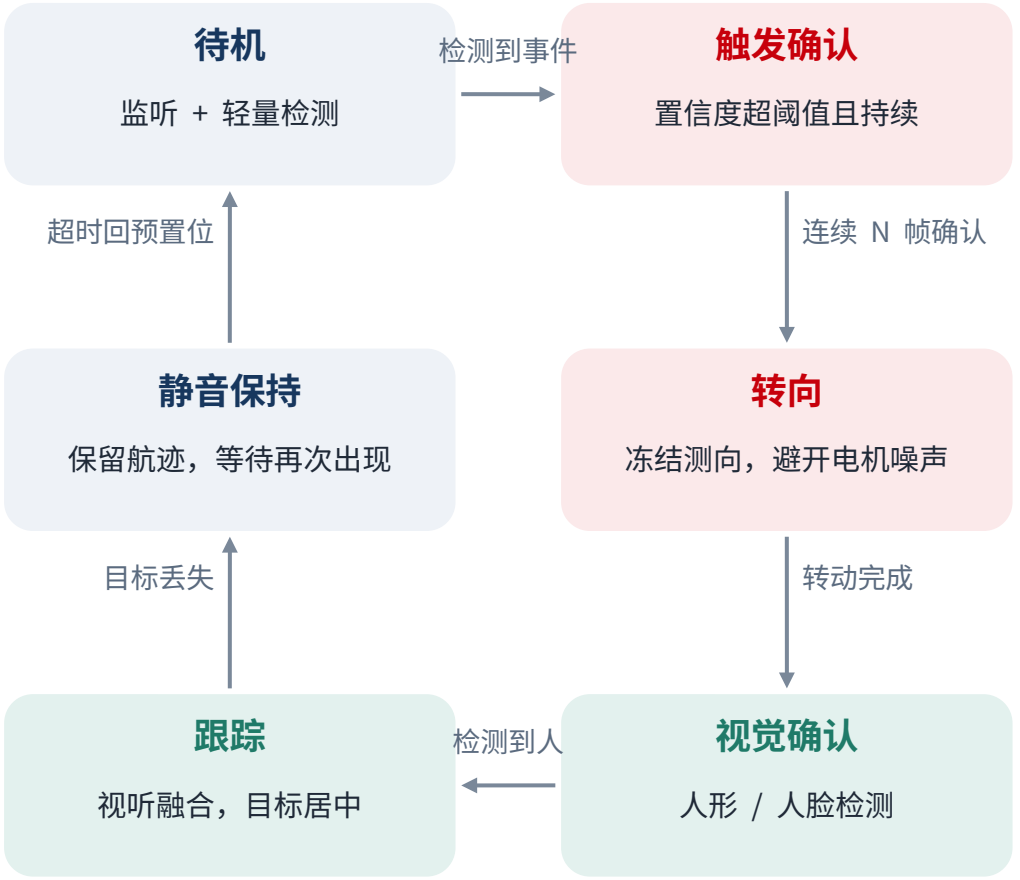
云台控制规则

确认：连续 N 帧置信度超过阈值才转，抑制瞬态误触发

死区：目标已在画面中央区域内不转，避免抖动

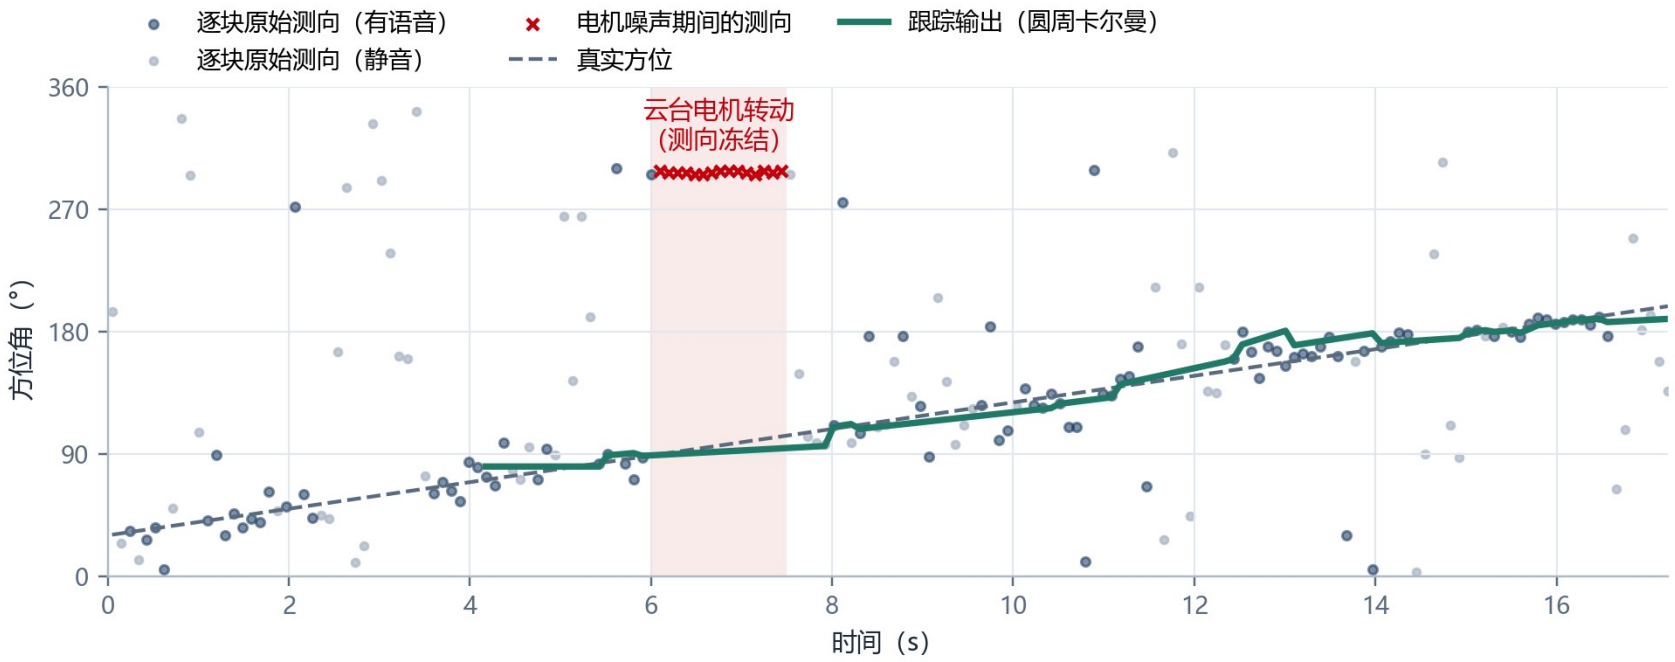
优先级：呼救 / 哭声 > 异常声 > 人声；同级按最近激活

干扰表：长时间固定方向、且视觉无人形的声源（如电视）记入干扰方向表



仿真示意：跟踪器把测向平均误差从约 22° 降到约 6°，电机转动时冻结测向避免被拉偏

做法： 4 麦方阵， RT60 = 0.5 s ；说话人沿 2 m 圆弧从 30° 走到 200°（约 17 s ）； 6.0–7.5 s 叠加近场电机噪声（比语音高 6 dB ）



22° → 6°

平均误差：逐块原始测向 → 跟踪输出

14%

有语音时，原始测向中误差 > 45° 的比例

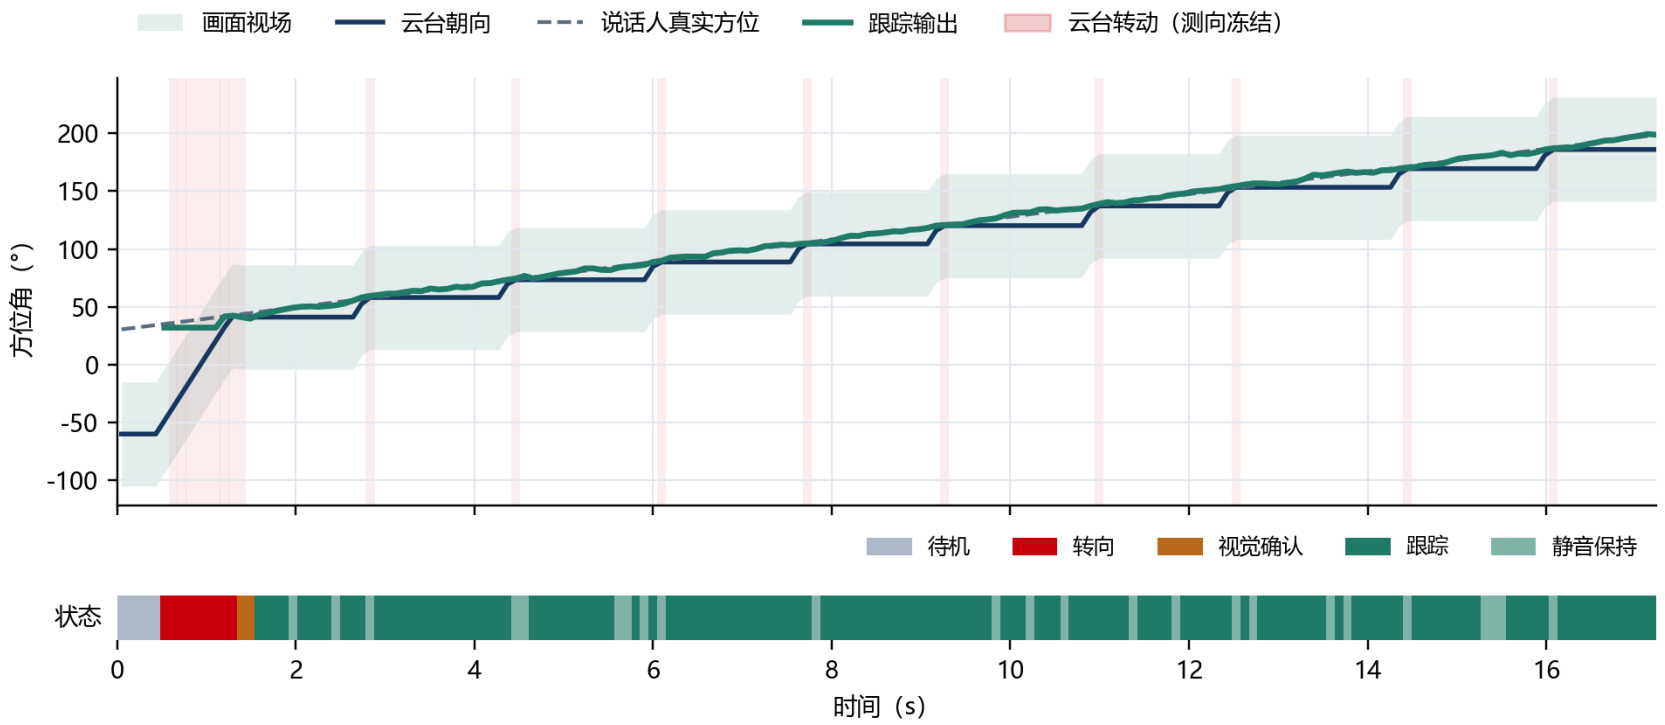
160°

电机转动期间原始测向的平均误差：不冻结就会被拉向电机

启示 单帧测向在混响下离散度很大，必须靠门控 + 跟踪 + 静音保持输出稳定方位；电机状态门控代价最低、收益最大。跟踪器参数未调优，属示意性结果。

闭环仿真：能量触发后 0.29 s 开始转向、 0.67 s 入画，之后 99% 时间在画面中央一半

做法：基线全链路闭环，能量触发（未接唤醒）；说话人在画面外开口并绕行 170°； RT60 = 0.5 s；视觉检测为模拟（画面内 90% 检出）



0.29 s

从能量触发到开始转动

0.67 s

从能量触发到目标进入画面

98.8%

入画后目标位于画面中央一半的时间比例

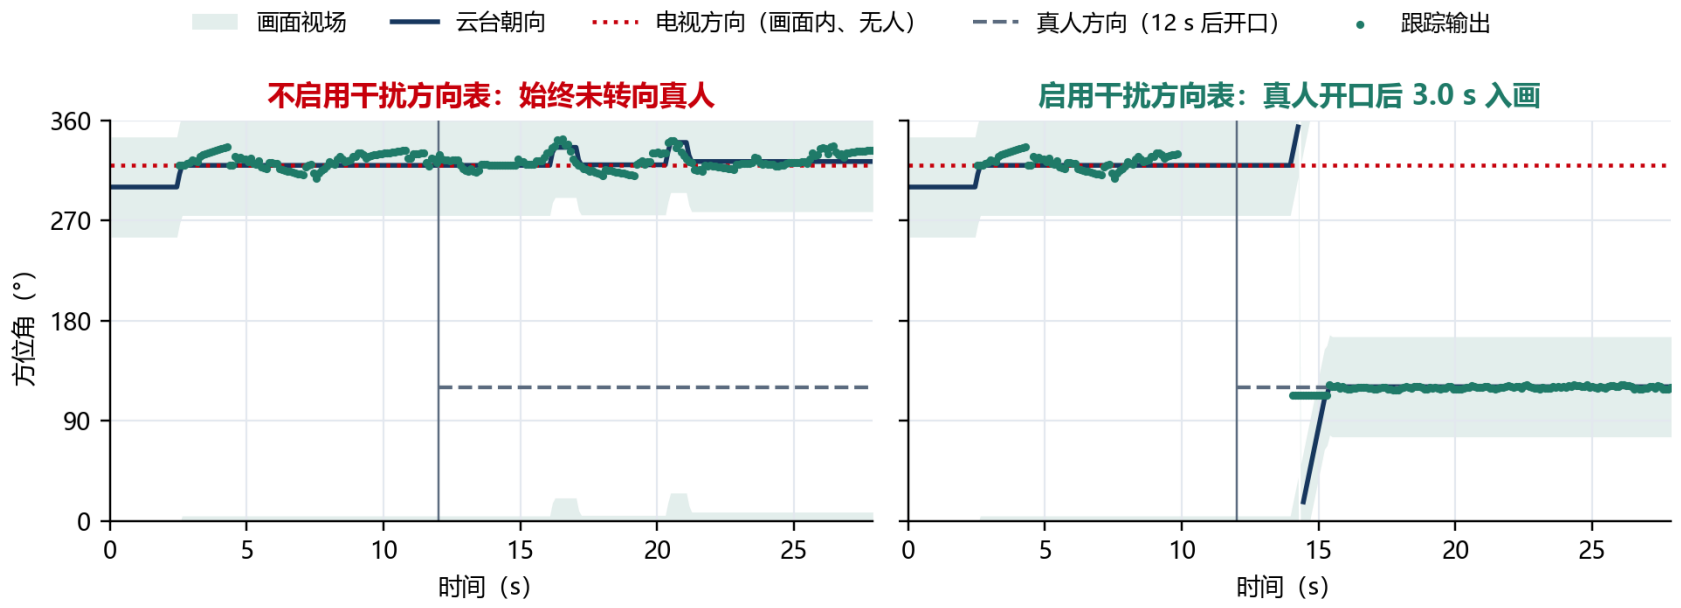
1.3°

融合视觉后的跟踪平均误差（17 s 内云台移动 10 次）

说明 计时起点为能量触发，与指标页从唤醒词结束计时的目标不直接对比。死区设计让云台“走走停停”而不是持续抖动；单声源、无干扰、 RT60 = 0.5 s 的理想场景，视觉为模拟，真实效果需在设备上复测。

电视干扰仿真：不启用干扰方向表时始终未转向真人；启用后 8 次中 7 次转向真人

做法：电视位于画面内、从 2 s 起持续播放人声（画面中无人）；真人 12 s 后在画面外 120° 处开口；其余设置同闭环仿真



不启用

跟踪器锁定电视；真人方向的观测被门控拒绝，云台始终不转

启用（左图示例）

“有声无人”累计 4 s 后屏蔽 310–330°；真人开口后 3.02 s 首次入画，从开口到仿真结束在画面内的比例 81.3%

8 个随机种子

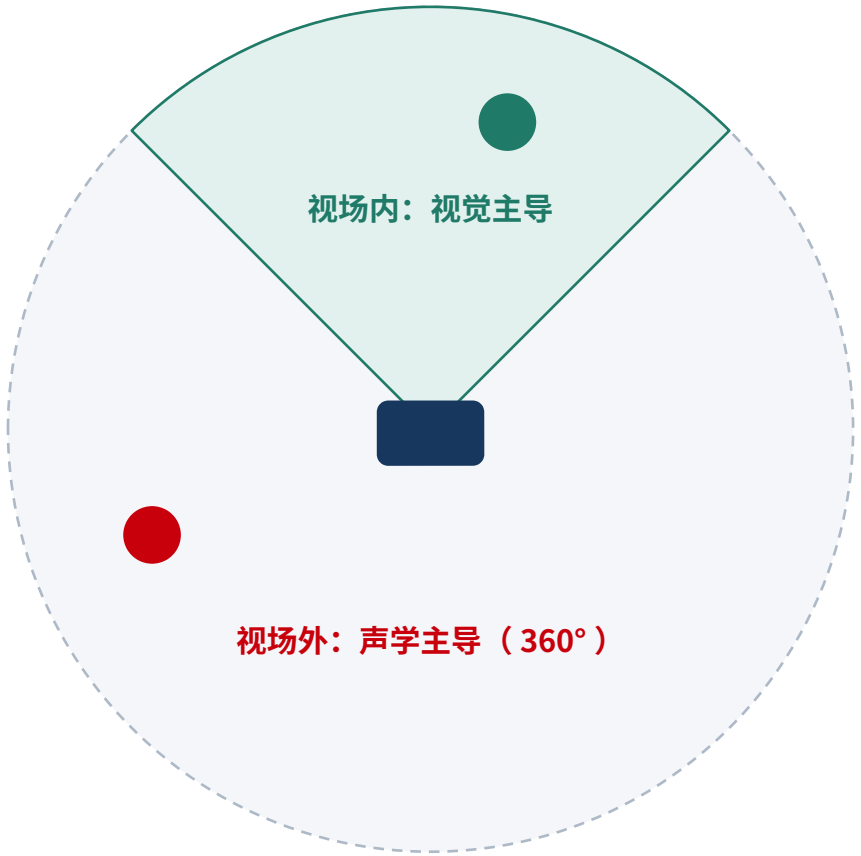
启用：7 次转向真人，其中 5 次 ≤ 3.1 s、2 次 11–13 s，1 次未转向；不启用：0 次

解除

若之后在该方向看到真人，自动解除屏蔽

启示 在该电视干扰仿真中，干扰方向表改善了目标重新捕获，实录待验证。纯声学难以区分电视里的人声和真人，“画面内长时间有声无人”这一视觉线索代价低；屏蔽时长、解除条件需在真实家庭数据上调参。唤醒词定向阶段另用唤醒前背景白化抑制电视。竞品中 Echo Show 10 采用让用户划定运动范围的方式处理类似问题。

视听融合：视场外靠声学找人，视场内由视觉精定位并确认谁在说话



1 坐标统一

像素横坐标 x 换算为方位： θ = θ 云台 + arctan((x − cx) / fx) ，落在设备固定坐标系；声学方位在底座固定时直接比对、随云台转时先加云台角；需做一次外参标定

2 说话人确认

Light-ASD （CVPR 2023）：约 1.0 M 参数、 0.6 GFLOPs， AVA-ActiveSpeaker 上 mAP 94.1%；用于多人画面中判断谁在说话

3 融合跟踪

粒子滤波：声学方位似然 × 视觉检测似然；参考 AV3T / CAV3D （摄像头与麦阵共址）、 STNet （2024）

DCASE 2025 任务 3 新增“画面内 / 画面外”声源判定子任务，与本场景直接对应

前沿趋势：从“单点测向”走向视听联合、声学成像与空间音频大模型

按对本项目的可用时间排序：近期可用 → 中期储备 → 远期探索

近期可用

视听联合与画面内外判定

DCASE 2025 任务 3：双通道立体声 + 普通视角视频，新增画面内 / 外声源判定

启示：直接对应“声音在不在画面里、要不要转”

近期可用

真实数据与跨阵列泛化

RealMAN （NeurIPS 2024）：真实录音训练优于仿真，可训练可变阵列网络； Neural-SRP （2024）适配任意几何

启示：一套模型适配多款阵列硬件

近期可用

端侧轻量化

Cross3D-Edge： 127 MFLOPS，树莓派 4B 8.6 ms/ 帧；LightDOA （2025）用 LLM 辅助生成仿真声学场景

启示：常开端侧测向在算力上已可行

中期储备

从“点”到“图”：声学成像

DCASE 2026 任务 3 （6 月已结束， 8 队 29 个提交）：只用 4 通道音频输出 1°/ 像素声能图；纯音频第一名 Mask mAP 仅 0.108

启示： 4 通道即可做，但精度尚低；可储备“画面叠加声源热力图”

远期探索

空间音频 + 大模型

BAT （ICML 2024）：空间音频编码器 + LLaMA-2 回答“在哪、是什么”；ELSA （NeurIPS 2024）空间音频 - 文本嵌入， 3D 定位误差约 15°

启示：支持“刚才玻璃碎的声音在哪”之类的语义查询

公开数据集：首轮评测用 LOCATA 与自录数据，网络训练以 RealMAN 为主

数据集（出处）	采集方式与阵列	动态声源	视频	规模	许可	本方案用途
LOCATA （2018 挑战赛；IEEE/ACM TASLP 2020）	真实； 4 类阵列（含 12 麦机器人头、助听器）	✓	—	Task 1： 单静止声源； Task 3： 单移动说话人（阵列均静止）	ODC-BY	**首轮： Task 1 静态测向、Task 3 移动跟踪**
自录唤醒词数据（待采集）	目标阵列或通用 4 麦阵列；标注唤醒词起止样点与方位真值	✓	可选	按 5 个演示场景采集	自有	**首轮：唤醒后首次定向与输出时延**
RealMAN （NeurIPS 2024）	真实； 32 麦阵列，可抽子阵；中文， 32 个场景	✓35 h	—	83 h 语音 +144 h 噪声	CC BY 4.0	网络阶段：训练与微调主力（抽几何接近的子阵）
Treble10 （2025）	物理精确仿真； 6 麦圆阵（半径 3 cm）设备冲激响应， 10 个带家具房间	—	—	3000+ 条冲激响应	6 通道语音子集 CC BY 4.0	网络阶段：小阵列高逼真仿真
MISP 2021 （挑战赛数据）	真实；远 / 中 / 近场麦克风 + 摄像机；中文， 34 个家庭电视房间	未注明	✓	141 h 音视频	非商用协议	仅研究：家居 + 电视干扰参考
STARSS23 （2023） / DCASE 2025 立体声版	真实； 4 通道四面体阵列 / FOA； 2025 版转为双通道 + 普通视角视频	✓	✓	约 7.5 h， 13 类事件，含画面内 / 外标签	MIT	储备：异响扩展、画面内外判定
SSLR （2018） / CAV3D （2019）	Pepper 机器人头 4 麦含风扇噪声 / 8 麦圆阵与摄像头共址	✓	CAV3D✓	约 25 h / 20 段序列	需申请，条款未公开	储备：小孔径、视听跟踪评测

数据年份不影响测向评测的物理有效性，关键看阵列几何与场景是否贴近。许可于 2026-11 按官方页面核实；非商用或条款未公开的数据仅用于研究对比。完整选型见《训练数据方案与采集计划》。

首轮实验：三组数据各回答一个问题；云台与唤醒的端到端验收留给设备实录

数据	回答的问题	对照	指标
LOCATA Task 1（固定阵列、单静止声源）	静态测向精度	SRP-PHAT 有 / 无起始段加权； MUSIC 作参照	MAE 、 Acc@10° 、粗大错误率
LOCATA Task 3（固定阵列、单移动说话人）	跟踪带来多少改善	同一 DOA 输出，有 / 无圆周卡尔曼跟踪	轨迹 MAE 、航迹覆盖率、粗大错误率
自录唤醒词数据（电视开 / 关）	唤醒后首次定向	SRP-PHAT ± 起始段加权 vs GEVD-MUSIC ；同一 MUSIC 有 / 无背景白化	Acc@10° 、粗大错误率、时延（词尾→回调、回调→输出）
仿真（已有脚本）	扩大房间与干扰条件覆盖	同自录唤醒词	同上

设备实录（验收依据）

采集： 3–5 类房间 × 8 个方位 × 3 个距离 × 4 种干扰（安静 / 电视 / 空调 / 电机转动）

端到端： 唤醒 → 定向 → 云台转动的时延与转向命中率；长时无人录音（含电视）测误转

网络阶段储备

仿真训练： gpuRIR / pyroomacoustics ，按产品几何， Treble10 小阵列高逼真补充；电视、音乐干扰；阵元扰动与通道失配

真实微调： RealMAN 子阵（训练与微调主力）；素材 AISHELL-1 、 DEMAND 、 MUSAN

评测分三层：帧级测向、轨迹跟踪、系统体验，各方案在同一测试矩阵上对比

1 帧级测向

- 方位平均绝对误差（ MAE ）
- Acc@10° / Acc@20°
- 粗大错误率（误差 > 45° ）
- SELD 联合指标：F1@20° 、 LE_CD 、 LR_CD （ DCASE ）

2 轨迹跟踪

- 轨迹平均误差
- 航迹断裂与丢失率
- 多人场景 ID 切换次数
- 参考 LOCATA 评测体系

3 系统体验

- 转向命中率
- 响应时延
- 误转率（次 / 小时）
- CPU / NPU 占用、内存、功耗

统一测试矩阵

RT60： 0.3 / 0.6 / 0.9 s × SNR： 20 / 10 / 0 dB × 声源数： 1 / 2 × 声源：静止 / 移动 × 电机：静止 / 转动

仿真与实录数据均按此矩阵出结果，各方案逐格对比，用数据决定是否进入下一阶段。

先做 demo：离线回放保底、实时演示加分，每周用同一组场景展示进展

演示场景固定，每周只换算法版本，进展一目了然

A 离线回放 demo （11 月起每周可演示）

- 输入：多通道录音（仿真 / 公开数据 / 实录） + 唤醒时间戳
- 流程：唤醒词片段测向 → 持续跟踪 → 云台状态机
- 展示：方位随时间曲线、俯视图上的说话人与云台指向
- 输出：每个场景的误差、时延统计

B 实时 demo （12 月中旬）

- 硬件：目标阵列或 4 麦 USB 阵列 + PC 【待确认】
- 流程：实时采集 → 唤醒（唤醒模块，或先用按键模拟）→ 方位显示
- 展示：虚拟 / 真实云台转向；波束成形前后的音频对比（可选）
- 输出：演示视频 + 实测时延

固定演示场景

① 正前方唤醒　② 侧后方唤醒（考察 360°）　③ 唤醒后边说边走　④ 电视开着时唤醒　⑤ 两人先后唤醒

每个场景记录：方位误差、定向时延、是否转对（目标进画面中央一半）、误转次数

原型路线： 11 月离线验证 → 12 月上中旬实录评测与实时 demo → 12 月下旬原型冻结

每个阶段用同一组演示场景出结果，结果决定下一阶段的重点

阶段	时间	内容	交付	状态
离线验证	11 月	唤醒词片段测向接口；离线 demo （仿真 + LOCATA ）；录音方案与录音脚本，阵列到位后先录一批	接口约定 v1 ；离线 demo 与误差表；录音方案 + 首批实录	**进行中：接口与仿真评测已完成**
实录评测与实时化	12 月上中旬	实录评测与调参；唤醒后持续跟踪；实时流式框架 + 方位显示（虚拟云台）；接入唤醒（或按键模拟）与波束成形接口	实录评测表；实时 demo 视频；实测时延	**待开始**
鲁棒性与冻结	12 月下旬	电视、强混响、两人先后唤醒；算力估计；原型冻结与总结	鲁棒性评测表；原型代码 + 报告 + 演示	**待开始**

保底与依赖　保底为离线回放 demo + 实录误差表，不依赖实时链路；实时 demo 依赖阵列与唤醒接口到位。原型阵列、唤醒时间信息、波束成形输出确认后定实录方案（见下页）。

主要风险与预案　阵列未到位 → 先用通用 4 麦 USB 阵列；唤醒接口未就绪 → 先用录音时间戳 / 按键模拟；真人唤醒时首次定向被电视拉偏 → 背景白化（ GEVD-MUSIC ）；电视自身触发唤醒 → 干扰方向表 + 视觉复核，待测。

待确认事项：前三项决定原型细节，后三项影响实录与端侧评估

1 阵列与 demo 硬件

麦克风数量、间距、安装位置（固定在底座还是随云台转动）？ demo 用哪块板或阵列?

2 唤醒接口

唤醒跑在单通道还是多波束？能否给出唤醒词起止样点、置信度与回调延迟？缓存能否覆盖唤醒词前约 1 s？

3 波束成形输出

需要定位输出什么（方位、置信度、更新率）？低置信度时希望保持方向还是退回宽波束?

4 芯片预算

目标 SoC 的算力、内存与常开功耗预算?

5 镜头与云台

水平视场角、云台转速、电机噪声水平?

6 数据

能否采集设备实录？能否拿到唤醒模块对录音的离线输出（起止样点）？