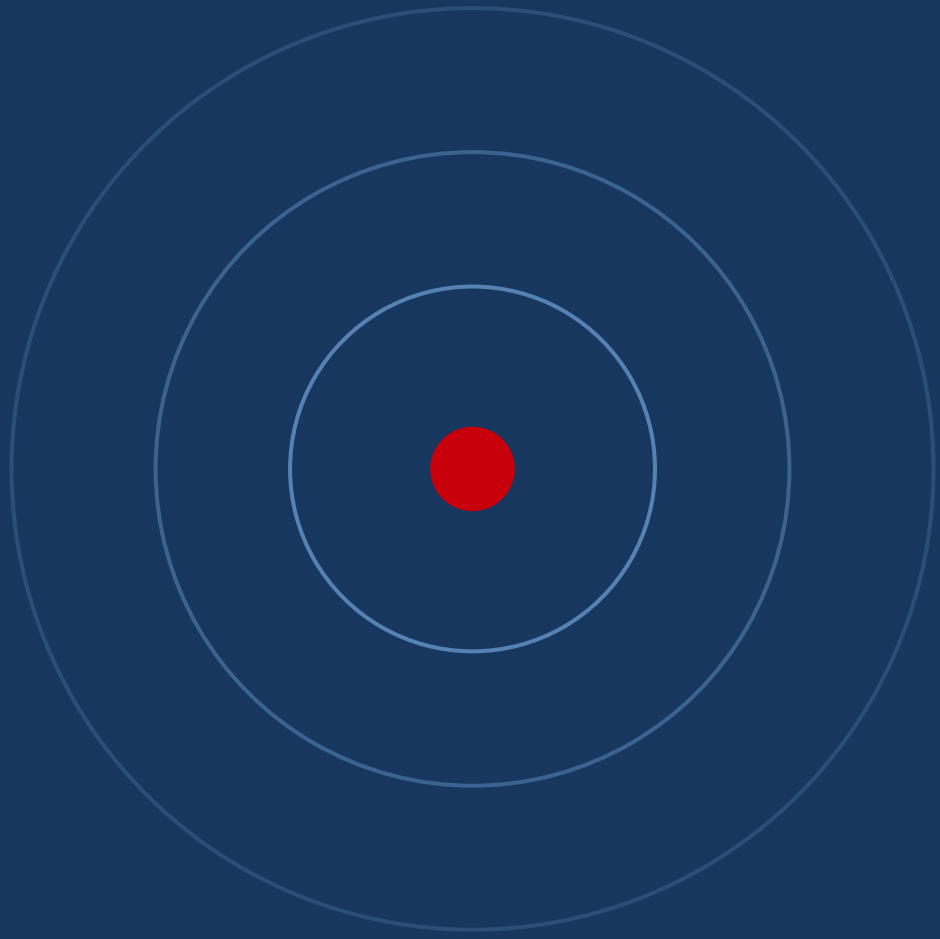
声源定位（SSL）调研 · 场景一 · 汇报精简版

摄像头声源定位与持续跟踪

需求拆解 · 方案选型 · 数据集 · 12 月原型计划

完整版（23 页）与竞品调研（14 页）另附



汇报人：令狐雅熙　2026.11

整体方向：唤醒 + 定位 + 波束成形协同，我负责声源定位，12 月底交付可演示的原型

mentor 负责语音唤醒；声源定位分三档推进：12 月原型 → 2027 Q1 网络升级 → 视听融合与异响扩展

B0 **本期：12 月原型**

唤醒词定向 + 持续跟踪

- 唤醒后用缓存的唤醒词片段测向（SRP-PHAT + 起始段加权）
- 持续跟踪说话人，方位实时给波束成形与云台
- 离线回放 + 实时两档 demo，每周迭代

M1 **2027 Q1：精度升级**

轻量神经网络测向

- 仿真显示短时间窗 + 混响是 SRP 的短板，由网络补足
- 唤醒已判断“是不是人声”，网络先做纯测向；SELD 留给异响
- 按产品阵列几何仿真训练，真实录音微调

E1 **后续扩展**

视听融合 + 异响事件

- 视场外靠声学，视场内交给人形 / 说话人检测
- 电视误唤醒：干扰方向表 + 视觉复核
- 哭声、玻璃破碎等异响也能触发转向

接口 语音唤醒（mentor）→ 唤醒词起止时间；声源定位（我）→ 每 100 ms 方位 + 置信度；波束成形 / 云台按方位对准（波束成形分工待确认）

三技术分工与接口：唤醒给“何时”，定位给“在哪”，波束成形与云台按方位执行

接口先按下表约定，周会上逐项确认；格式可随 mentor 的唤醒模块调整

麦克风阵列
16 kHz； 2 s 环形缓存

→

语音唤醒（mentor）
检测唤醒词 → 起止时间、置信度

→

声源定位（我）
唤醒词片段测向 + 持续跟踪

→

波束成形（分工待确认）
按方位增强说话人语音

→

云台与视觉
转向、视觉确认、居中

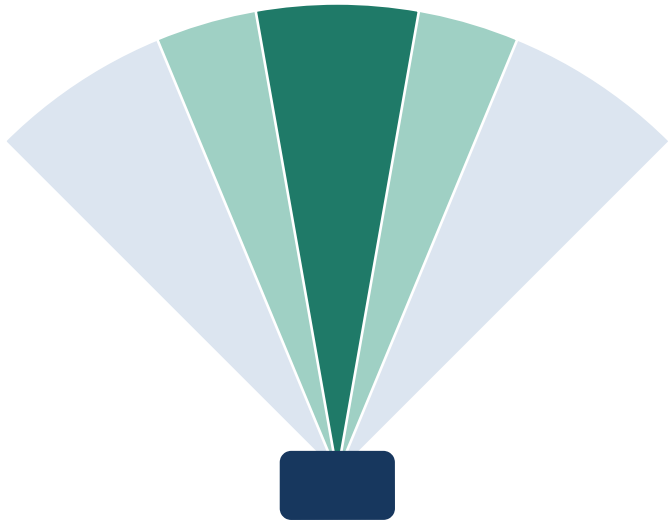
接口	内容	建议格式	状态
阵列 → 各模块	麦克风数量、几何、采样率、帧长、缓存长度	16 kHz；帧 16 ms；环形缓存 ≥ 2 s	**待确认**
唤醒 → 定位	触发时刻、唤醒词起止样点、置信度；唤醒跑在哪个通道 / 波束	回调或消息；样点级时间戳	**待对齐**
定位 → 波束成形	方位（俯仰可选）、置信度、更新时刻	每 100 ms；低置信度时保持上一方向	**待对齐**
定位 → 云台	世界坐标方位、是否转动；读取云台角与电机状态	状态机输出（死区、确认、冻结）	**原型已有**

需和 mentor 定的一个设计选择 唤醒若跑在多个固定波束上，可直接用得分最高的波束作粗方向；但 Amazon 指出波束选择不适合直接驱动转动，所以建议“先唤醒、再用唤醒词片段精确测向”。

精度要求由镜头视场反推：方位误差小于 HFOV/4，目标即落在画面中央一半

允许误差 ≤ HFOV / 4

转向后目标落在画面中央一半，就能交给视觉精对准。以 HFOV = 90° 为例，允许 ±22.5°；取 ±10° 作设计目标，为人员移动和跟踪延迟留余量。



水平视场 HFOV = 90°（示例）
中央一半：±22.5°
设计目标：±10°

建议指标（目标值待与产品需求对齐）

指标	定义	建议目标
方位误差	单声源、RT60 ≤ 0.6 s、SNR ≥ 10 dB 下的平均绝对误差	**≤ 10°**
转向命中率	转动结束后目标位于画面中央一半的比例	**≥ 90%**
粗大错误率	误差 > 45°（含前后混淆）的比例	**≤ 3%**
定向 / 转向时延	唤醒词结束 → 输出方位 / 云台开始转动	**≤ 0.1 s / ≤ 0.5 s**
误转率	无有效唤醒时的转动次数（含电视误唤醒）	**≤ 1 次 / 小时**
端侧开销	常开链路的算力、内存与功耗	**【待定】**

测向算法对比： 12 月原型用 SRP-PHAT； Q1 换轻量网络提升短时精度， SELD 留给异响扩展

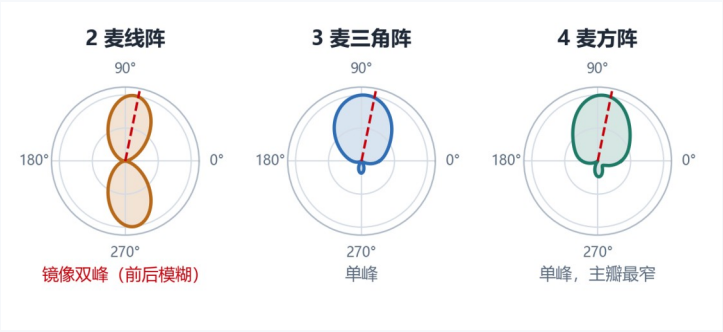
方法（出处）	原理	混响 / 噪声鲁棒	多声源	事件类别	端侧开销	定位
GCC-PHAT	麦克风对时延估计	**中**	弱	无	极低	2 麦方案组件
SRP-PHAT （pyroomacoustics 可复现）	在 5° 网格（72 个方向）上扫描各麦克风对的 PHAT 能量	**中**	**中**	无	低	**12 月原型 B0**
NormMUSIC	子空间谱估计	弱（相干反射）	**强**	无	中（逐频点特征分解）	对照
Cross3D-Edge （ACM TECS 2023）	SRP 功率图 + 裁剪后的 3D CNN	**强**	单声源	无	127 MFLOPS；树莓派 4B 8.6 ms/ 帧	单声源备选
LightDOA （arXiv 2025）	双通道 IPD + 深度可分离卷积 + GRU， 0–180° 按 5° 分类	**中**	弱	无	低	2 麦方案备选
轻量 SELD： SALSA-Lite + 深度可分离 CRNN + Multi-ACCDOA	多通道对数谱 + 归一化 IPD，逐帧输出“类别 × 方向向量”	**强**	**强（同类重叠可分）**	**有**	中，可裁剪	**Q1 网络方向 M1 （异响时用 SELD）**
FN-SSL / IPDnet （Interspeech 2023 / 2024）	全带 - 窄带融合估计直达声 IPD，面向移动声源	**强**	**强（IPDnet）**	无	较高	精度参照 / 教师模型

评级综合各论文报告与原理分析，最终以统一测试矩阵复测为准； Neural-SRP （IEEE OJSP 2024）可适配任意阵列几何，若后续有多款硬件再引入。

初步仿真验证：阵列选择、闭环跟踪、电视干扰三组结果都支持推荐方案

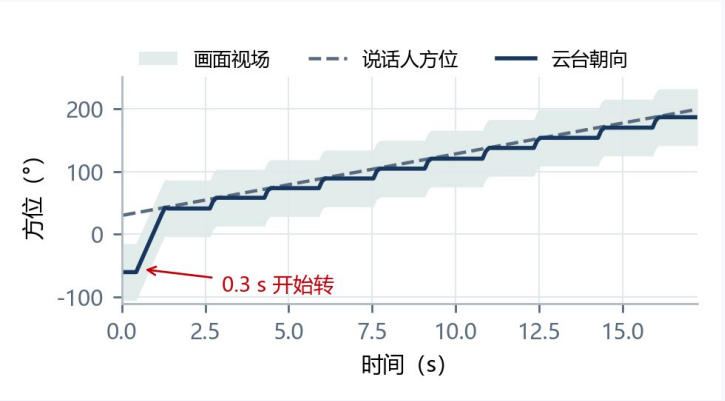
镜像源法仿真 + 模拟视觉；设置与更多结果见完整版第 9 、 13–15 页

阵列： 3 / 4 麦可用， 2 麦不行



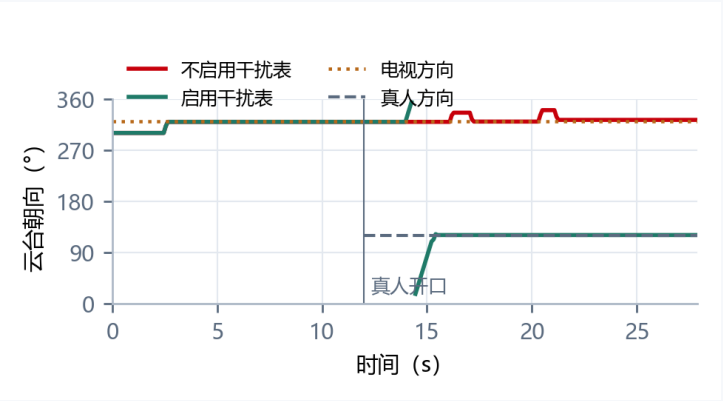
- 2 麦： 37–61% 落在镜像方向
- 3 / 4 麦：累积 2.5 s 时误差约 2–10°
- 单帧精度随混响快速下降 → M1 的核心任务

闭环： 0.3 s 开始转， 0.7 s 入画



- 入画后 98.8% 时间在画面中央一半
- 17 s 内云台只动 10 次（死区防抖）
- 融合视觉后跟踪误差约 1.3°

电视：干扰方向表是必备功能



- 不启用：被电视“锁死”，始终不转向真人
- 启用：真人开口 3 s 内入画
- 看到真人自动解除屏蔽

局限与下一步 单声源、鞋盒房间、视觉为模拟；下一步在公开真实数据（ LOCATA 、 RealMAN ）和设备实录上复核，并以此定最终指标。

原型架构：唤醒触发 → 唤醒词片段测向 → 持续跟踪 → 方位同时驱动波束成形与云台

4 麦阵列
16 kHz； 2 s 环形缓存

→

语音唤醒（mentor）
输出唤醒词起止时间与置信度

→

特征提取
STFT 32 ms； PHAT 加权互谱（原型） / SALSA-Lite （Q1 网络）

→

测向
原型： SRP-PHAT + 起始段加权； Q1 ： 轻量网络

→

输出
每 100 ms ： 方位 + 置信度

↓

坐标变换
方位 + 云台编码器角 → 世界坐标

←

跟踪器
一期：圆周卡尔曼；三期：粒子滤波

←

转向决策
置信度确认、优先级、死区、干扰方向表

←

执行
云台转向 + 波束对准 → 视觉接管

电机状态：转动中冻结测向

视觉人形框：视听融合（三期）

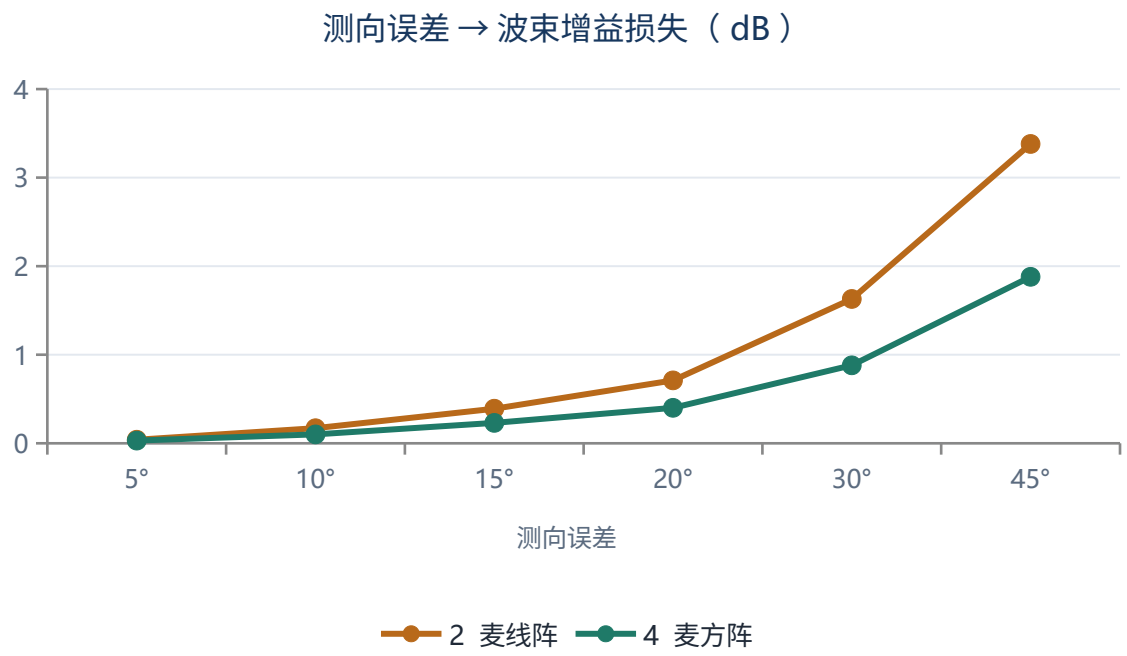
唤醒词片段测向
唤醒词约 0.5–1 s 语音集中测向，不需要事件分类

给波束成形
方位 + 置信度；低置信度时保持上一方向（见下页）

原型算力【待定】
SRP-PHAT： 4 麦 6 对 × 119 频点 × 360 方向 / 帧；可降到 5° 网格

波束成形对测向的要求： ±10° 足够做延迟求和；小阵列难点在低频指向性，需要置信度配合

计算：延迟求和波束按估计方向对准、信号来自真实方向时的增益损失（ 300–4000 Hz 平均，孔径 5.7 cm ）





4 麦方阵延迟求和波束图： 1 kHz 几乎全向， 3 kHz 主瓣变窄， 6 kHz 出现栅瓣

测向够用： 4 麦误差 10° 仅损失约 0.1 dB， 20° 约 0.4 dB

真正瓶颈： 孔径小， 1 kHz 以下延迟求和几乎无指向性，需超指向 / MVDR 类方法

配合要求： 这类方法对方向误差更敏感（判断，待仿真验证），定位须给置信度，低置信度时保持方向或退回宽波束

对定位的要求 方位误差 ≤ 10° 、每 100 ms 更新、带置信度；波束成形算法本身的选型由负责人决定（分工待确认）。

先做 demo：离线回放保底、实时演示加分，每周用同一组场景展示进展

演示场景固定，每周只换算法版本，进展一目了然

A 离线回放 demo （11 月第 2 周起每周可演示）

- 输入：多通道录音（仿真 / 公开数据 / 实录） + 唤醒时间戳
- 流程：唤醒词片段测向 → 持续跟踪 → 云台状态机
- 展示：方位随时间曲线、俯视图上的说话人与云台指向
- 输出：每个场景的误差、时延统计

B 实时 demo （12 月中旬）

- 硬件：目标阵列或 4 麦 USB 阵列 + PC【待确认】
- 流程：实时采集 → 唤醒（mentor 模块，或先用按键模拟）→ 方位显示
- 展示：虚拟 / 真实云台转向；波束成形前后的音频对比（可选）
- 输出：演示视频 + 实测时延

固定演示场景

① 正前方唤醒　② 侧后方唤醒（考察 360°）　③ 唤醒后边说边走　④ 电视开着时唤醒　⑤ 两人先后唤醒

每个场景记录：方位误差、定向时延、是否转对（目标进画面中央一半）、误转次数

12 月底原型计划：11 月每周 2 天做离线验证，12 月全职做实时 demo 与集成

按实际投入约 28 个工作日（11 月 6 天、12 月约 22 天，12/25 假期）；每周与 mentor 讨论一次

周	日期	投入	目标	周会交付
W1	11/09–11/15	2 天	对齐接口、demo 硬件与验收指标；代码改成“唤醒词片段测向”接口	接口约定 v1
W2	11/16–11/22	2 天	离线 demo A v0：仿真 + 公开数据（LOCATA）	离线 demo；首版误差表
W3	11/23–11/29	2 天	录音方案与录音脚本；若阵列已到，先录一小批	录音方案 + 首批实录
W4	11/30–12/06	**全职**	实录评测与调参；唤醒后持续跟踪	实录评测表
W5	12/07–12/13	**全职**	实时流式框架 + 方位显示（虚拟云台）	实时运行；时延实测
W6	12/14–12/20	**全职**	接入唤醒（或按键模拟） + 波束成形接口；端到端 demo	实时 demo B 视频
W7	12/21–12/27	**全职 4 天**	鲁棒性：电视、强混响、两人场景；算力估计	鲁棒性评测表
W8	12/28–12/31	**全职 4 天**	原型冻结、报告与演示；Q1 计划	原型代码 + 报告 + demo

主要风险与预案 阵列未到位 → 先用通用 4 麦 USB 阵列；唤醒接口未就绪 → 先用录音时间戳 / 按键模拟；电视误唤醒 → 干扰方向表 + 视觉复核。

首次周会要对齐的六件事：硬件、唤醒接口、波束成形分工决定原型细节

1 阵列与 demo 硬件

麦克风数量、间距、安装位置？ demo 用哪块板或阵列？

2 唤醒接口

唤醒跑在单通道还是多波束？能否给出唤醒词起止时间与置信度？

3 波束成形

由谁负责？需要定位输出什么（方位、置信度、更新率）？

4 芯片预算

目标 SoC 的算力、内存与常开功耗预算？

5 镜头与云台

水平视场角、云台转速、电机噪声水平？

6 数据与周会

能否录设备实录？每周讨论的时间与形式？