场景一专项调研 · 讲解手册

摄像头声源定位与持续跟踪 | 配套：主方案 PPT 23 页 + 精简版 11 页 + 竞品 PPT 14 页 + 调研清单 + 基线代码 | 2026-11-09

本手册给自己用，不给 mentor 看。PPT 已按“给 mentor 看”的标准做干净；这里放讲稿、追问应答、原 PPT 核对清单、概念速查和全部出处。

零、方向更新（2026-11-09 mentor 补充）

mentor 原话要点：场景一主要涉及三个技术——语音唤醒 + 声源定位 + 波束成形；语音唤醒 mentor 正在做；声源定位要在 12 月底前出一个算法原型；之后每周讨论一次；先做 demo。

1. 怎么理解整体方向

- **这是一条产品链路，不是三个独立课题：**用户说唤醒词 → 唤醒模块判断“有人在叫我”并给出唤醒词的时间 → 定位用这段语音算出“人在哪” → 波束成形把麦克风“对准”这个人，提升后续命令识别或通话的音质；同时云台转过去、视觉接管。
- **你的位置在中间：**上游吃唤醒的触发和时间戳，下游给波束成形和云台方位。所以接口和时延和精度一样重要。
- **12 月底的“算法原型”是什么：**唤醒词定向（用唤醒词片段测出方位）+ 唤醒后持续跟踪 + 给波束成形 / 云台的方位输出，并能演示。神经网络、视听融合、异响都是之后的事。

2. 和之前方案相比改了什么、为什么改

这次调整的依据是 mentor 补充的新信息（触发方式是语音唤醒），不是推翻之前的分析：

项目	之前	现在	原因
触发	能量 / 谱通量检测 + 事件分类	语音唤醒（mentor 模块）	唤醒已经判断了“是不是在叫设备”
主方案 M1	轻量 SELD（事件 + 方向一体）	轻量神经网络纯测向（Q1）；SELD 留给异响	唤醒负责“是什么”，定位只需管“在哪”
新增模块	—	波束成形接口（方位 + 置信度）	mentor 明确场景包含波束成形
计划	P0–P3 阶段（约 13 周）	到 12 月底约 28 个工作日（11 月每周 2 天、12 月全职）+ 每	有了明确交付时间和周会节奏

		周 demo	
不变	SRP-PHAT 基线、跟踪器、云台状态机、电视干扰表、数据集	同左	这些正是原型的主体，代码已有雏形

3. 12 月底原型的验收清单（建议，首次周会确认）

- 唤醒词结束后 0.1 s 内输出方位；4 麦方位误差 ≤ 10°（安静、中等混响）
- 唤醒后持续跟踪，方位每 100 ms 更新，并给出置信度
- 云台状态机可用：死区、确认、转动冻结、电视干扰方向表
- 离线 demo（五个固定场景）+ 实时 demo（视硬件到位情况）
- 一份评测表：每个场景的误差、时延、转对率、误转次数；一份算力估计

4. 每周讨论怎么准备（模板）

环节	内容	时长
① 本周结果	固定五个场景的 demo + 指标表（和上周对比）	5 分
② 问题与分析	失败案例（附录音 / 曲线），我的判断和原因	3 分
③ 需要 mentor 决定	最多 2–3 件，给出选项和我的建议	3 分
④ 下周计划	对应周计划表的下一行，说清交付物	2 分

小贴士：每周用同一组场景和同一张指标表，进展最直观；结论写“查到的事实 / 我的仿真 / 我的判断”三类，避免被追问后改口。

5. 时间安排（按实际投入）

11 月每周 2 天、12 月全职（每周 5 天），到 12 月底约 28 个工作日（11 月 6 天、12 月约 22 天，12/25 圣诞节假期）。所以 11 月只做离线验证和准备（接口、离线 demo、录音方案），12 月集中做实时 demo 和集成。现有的仿真和基线代码已经覆盖离线 demo 的大部分，11 月的 6 天是够的。

周	日期	投入	做什么	交付
W1	11/09–11/15	2 天	对齐接口、demo 硬件、验收指标；代码改成唤醒词片段测向接口	接口约定 v1
W2	11/16–	2 天	离线 demo v0（仿真 + LOCATA）	离线 demo、误差表

	11/22			
W3	11/23–11/29	2 天	录音方案与脚本；阵列到了就录一小批	录音方案、首批实录
W4	11/30–12/06	全职	实录评测与调参；唤醒后持续跟踪	实录评测表
W5	12/07–12/13	全职	实时框架 + 方位显示（虚拟云台）	实时运行、时延
W6	12/14–12/20	全职	接入唤醒 / 按键模拟 + 波束成形接口；端到端 demo	实时 demo 视频
W7	12/21–12/27	全职 4 天	鲁棒性（电视、混响、两人）；算力估计	鲁棒性评测表
W8	12/28–12/31	全职 4 天	冻结原型、报告、演示；Q1 计划	原型 + 报告 + demo

一、怎么用这份材料

1. 交付物一览

文件	给谁看	内容
场景一专项_汇报精简版.pptx	mentor（周会主讲）	11 页约 14 分钟：方向与分工、接口、指标、算法、仿真、架构、波束成形要求、demo、周计划、待确认
场景一专项_摄像头声源定位与跟踪_方案选型与数据集.pptx	mentor	主方案 23 页：方向与分工、三技术接口、指标、阵列 / 算法 / 跟踪 / 视听选型、波束成形要求、4 页仿真、前沿、数据集、评测、demo 方案、12 月周计划
声源定位竞品调研_听声转向与发言人跟踪.pptx	mentor	竞品 14 页（含 2 页产品图卡片，来源可点击）：家用摄像头、Echo Show 10 拆解、会议摄像头、芯片方案、定位矩阵、痛点、启示、实测方案
声源定位调研清单_文献数据集工具竞品.xlsx	mentor / 自己	文献 25 篇、数据集 15 个、工具 8 个、竞品 15 个、待确认问题追踪表
code\ssl_baseline	自己（可演示）	基线 B0 可运行原型：测向、跟踪、云台状态机、仿真、评测、9 个单元测试

本手册	自己	讲稿、追问应答、代码与仿真说明、原 PPT 核对清单、概念速查、出处

建议插入位置：主方案整体作为“场景一专项”章节，放在原调研 PPT 第 15 页（“落地场景·场景一”）之后；竞品 PPT 可作为独立附件，或把第 2、5、8 页并入主方案。

1.5 周会用精简版：逐页讲法（约 14 分钟）

建议周会只讲精简版，完整版和竞品调研作为附件，被追问时再翻到对应页。

页	内容	时长	一句话要点
1	封面	0.5 分	这次讲场景一的整体方向、声源定位方案和 12 月原型计划
2	整体方向	1.5 分	唤醒（mentor）+ 定位（我）+ 波束成形；本期交付唤醒词定向 + 持续跟踪原型
3	三技术接口	1.5 分	唤醒给“何时”，定位给“在哪”；接口表逐项确认；建议先唤醒再精确测向
4	精度指标	1 分	误差 ≤ HFOV/4；唤醒结束 → 方位 ≤ 0.1 s、→ 云台开始转 ≤ 0.5 s
5	算法矩阵	1.5 分	原型用 SRP-PHAT；Q1 用轻量网络；SELD 留给异响
6	仿真验证	2 分	2 麦镜像不行；闭环 0.3 s 开始转；电视干扰表必备
7	原型架构	1 分	唤醒触发 → 唤醒词片段测向 → 跟踪 → 方位驱动波束与云台
8	波束成形要求	1.5 分	4 麦误差 10° 仅损失约 0.1 dB；难点是小阵列低频指向性；要给置信度
9	demo 方案	1 分	11 月离线回放保底、12 月中实时演示；五个固定场景每周复测
10	原型计划	1 分	11 月每周 2 天做离线、12 月全职做实时与集成；约 28 个工作日
11	首次周会六件事	1 分	先定 demo 硬件、唤醒接口、波束成形分工

2. 实习电脑传不了文件怎么办

先按公司规定确认能否把文件“传进”实习电脑（很多环境只禁止往外传）。能传进就直接插入；不能就对照 PDF 在原文件里重建，时间紧时按下面的优先级：

优先级	主方案页码	竞品页码	原因
必做	2、4、8、9、10、21、22、23	2、4、5	方向、接口、算法矩阵、仿真、架构、demo、周计划、待确认；竞品结论与产品图
建议	3、5、7、11、14、	6、7、8	闭环、指标、阵列、波束成形要求、闭环与电视仿真、数

	15、18		据集；竞品表格与矩阵
可选	其余	其余	时间够再补，或口头讲

3. 汇报时的口径（重要）

- **查到的事实：**论文结论、数据集规模 / 许可、Cross3D-Edge 与 Light-ASD 的开销数字、竞品功能（标了 A/B/C 证据等级），均有出处。
- **我的仿真：**第 9、11、13–15 页的数字来自镜像源法仿真 + 模拟视觉，说“初步仿真表明”，并主动说明局限（无家具散射、无真实噪声、视觉为模拟）。
- **我的建议（判断）：**推荐 4 麦、KPI 目标值、网络规模、仿真参数、阶段周期、“芯片级参考方案是机会”。讲的时候用“建议 / 初定 / 判断”。
- **测向矩阵的“强 / 中 / 弱”**是综合论文与原理的定性判断，不是同一测试集上的排名。

二、整体逻辑：一句话 + 三个为什么

一句话：场景一的声学部分不追求极高精度，而追求“稳”——不转错、不乱转、反应快；12 月原型用唤醒词片段 + SRP-PHAT 测向、跟踪器维持航迹，方位同时给波束成形和云台；Q1 再用轻量网络提升短时精度；视场内交给视觉。

为什么基线是 SRP-PHAT?

免训练、可解释、计算量小（5° 网格只有 72 个候选方向），pyroomacoustics 有现成实现，几天就能出结果；它既是闭环打通的最快路径，也是后续网络方案的对照基准，网络出问题时还能兜底。GCC-PHAT 只用一对麦克风，抗噪和多声源能力更弱，只在 2 麦方案中用。

为什么原型用 SRP-PHAT，Q1 才上神经网络?

12 月底要交可演示的原型，SRP-PHAT 免训练、可解释，几天就能跑通，而且有唤醒词片段（0.5–1 s 的确定人声）可用，累积后精度已够（仿真 2–10°）。网络的价值在短时间窗 + 强混响下的单帧精度，属于 Q1 的精度升级；因为唤醒已经负责“是不是在叫设备”，网络先做纯测向，SELD（事件 + 方向）留给以后的异响场景。

为什么一定要视听融合?

纯声学在家庭场景有三个解决不了的问题：说话停顿时没有观测、多人时不知道谁在说话、电视里的人声会被当成真人。摄像头本来就有人形检测，把它和声学方位放进同一个跟踪器，三个问题都能缓解。

三、逐页讲稿与追问应答

P1 分隔页

讲稿 本部分针对场景一展开：先拆解需求和指标，再给出阵列、测向算法、跟踪与视听融合的具体选型，最后是数据集、评测方案和实施计划。

P2 整体方向（结论先行）

讲稿 场景一由语音唤醒、声源定位、波束成形三项技术协同完成：唤醒由 mentor 在做，我负责声源定位，12 月底交付可演示的原型，之后每周讨论。定位分三档：本期 B0 唤醒词定向 + 持续跟踪（SRP-PHAT + 起始段加权 + 跟踪器），方位同时给波束成形和云台；Q1 用轻量网络提升短时精度，唤醒已判断是不是人声，网络先做纯测向；之后是视听融合和异响扩展。

【若被问】为什么 M1 从 SELD 改成纯测向?

依据是新信息：触发方式确定为语音唤醒，“是什么声音”由唤醒负责，定位只需要“在哪”。SELD 没有被否定，留到异响场景再用。

【若被问】12 月底的原型具体指什么?

唤醒词定向 + 唤醒后持续跟踪 + 给波束成形和云台的方位输出，加离线 / 实时 demo 和一份评测表。

P3 场景闭环：唤醒 → 定向 → 转向与波束 → 视觉 → 跟踪

讲稿 用户说唤醒词，唤醒模块给出起止时间；我用这段唤醒词测出方向并换算到世界坐标；云台转过去、波束指向说话人，转动时冻结测向；视觉确认后持续跟踪，方位不断更新给波束和云台。已有先例：华为智选雀蛋 Pro 喊“海雀海雀”会转向说话人，Echo Show 10 也是唤醒词转屏。

【若被问】为什么转动时要冻结测向?

云台电机就在麦克风旁边，是强近场噪声；仿真里电机期间的测向平均偏了约 160°，不冻结就会被拉偏。

P4 三技术分工与接口

讲稿 唤醒告诉大家“什么时候”有人在叫设备，并给出唤醒词起止时间；定位告诉大家“人在哪”，每 100 ms 输出方位和置信度；波束成形和云台按方位执行。接口表是我建议的格式，阵列参数和唤醒输出要和 mentor 确认，云台侧原型代码已有状态机。还有一个设计选择：唤醒若跑在多波

束上，最高分波束可作粗方向，但 Amazon 指出波束选择不适合直接驱动转动，所以建议先唤醒、再用唤醒词片段精确测向。

【若被问】为什么要唤醒词的起止时间?

定位要用“正好是这个人说话”的那段音频：有了起止时间，就能从环形缓存里取出唤醒词片段集中测向，既准又快；没有的话只能猜，容易把电视或别人的声音算进来。

【若被问】环形缓存为什么要 2 s?

唤醒词一般 0.5–1 s，唤醒判决还有延迟，留 2 s 保证触发时唤醒词整段仍在缓存里。具体长度按 mentor 唤醒模块的延迟定。

P5 精度指标：由视场反推

讲稿 精度要求可以从镜头视场反推：转向后只要目标落在画面中央一半，视觉就能接手，所以允许误差是水平视场角的四分之一。以 90 度视场为例是正负 22.5 度，取正负 10 度作设计目标，给人员移动和延迟留余量。所以难点不是精度，而是稳健：粗大错误率、误转率和响应时延更关键。右边都是建议值，需要和产品需求对齐，端侧开销要等目标芯片确定。

【若被问】为什么是 HFOV/4?

画面中央一半对应 ±HFOV/4 的角度范围（总宽 HFOV/2）。目标在这个范围内，人形检测一般能完整框出，视觉可以直接接手居中。

【若被问】±10° 依据是什么?

这是建议值：在 ±22.5° 的允许范围内留一倍余量，覆盖人走动和转动耗时。原调研 PPT 里思必驰六麦环形 ±10° 的数据与此量级一致。最终要按产品 HFOV 重算。

【若被问】90° 是我们产品的视场吗?

不是，只是示例。公式不变，换成实际 HFOV 即可。

P6 五个工程难点

讲稿 这五个难点决定了后面的选型：小孔径少阵元带来低频分辨率差、高频空间混叠和 2 麦前后模糊；家庭混响和电视是误转主要来源；云台电机自噪声和阵列随转动；人说话有停顿、会移动、会多人；常开链路必须低功耗。右列是对策，后面几页逐一展开。

【若被问】空间混叠是什么?

阵元间距超过半个波长时，不同方向会产生相同的相位差，角度出现歧义。临界频率 $f = c/(2d)$：$d = 4$ cm 时约 4.3 kHz，$d = 5$ cm 时约 3.4 kHz。所以空间特征只取这个频率以下。

【若被问】PHAT 加权为什么抗混响?

PHAT 把互功率谱幅度归一化，只保留相位，相当于把相关峰“锐化”，让直达声的峰和反射的峰更容易分开；但混响很强时仍会出伪峰，所以还要配合时频点筛选。

【若被问】直达声主导的时频点怎么筛?

常用做法是只用起始段（onset）或空间相干性高的时频点，反射声到达更晚、相干性更低；具体方法列入 B0 的调优项。

P7 阵列构型

讲稿 算法要先看硬件。2 麦线阵成本最低，但前后对称，只能测 0–180°；可以让云台小角度转一下，根据方位变化方向消除前后模糊，这是机器人听觉里成熟的做法。3 麦以上平面阵覆盖 360°。推荐 4 麦，因为能直接用 4 通道 SALSA-Lite 和 DCASE 体系的网络，也能分辨更多声源。安装位置也关键：装在底座坐标系不变；装在云台头上要用编码器角度换算，转动时相当于移动阵列。

【若被问】2 麦怎么用转动消歧?

线阵只能测与阵列轴的夹角，前方 φ 和后方镜像位置给出相同时延。云台转 +Δ 后，前方声源的测量角变为 φ−Δ，后方声源对应的测量角变为 φ+Δ，变化方向相反，比较前后两次测量即可判断。参考 Ma, May & Brown（IEEE/ACM TASLP 2017）用头部转动消除前后混淆。

【若被问】为什么推荐 4 麦而不是 6 麦?

这是成本与能力的折中判断：4 麦已能覆盖 360°、做 4 通道 SELD；6 麦能提升分辨率和多源能力，但成本和算力更高。最终取决于产品定位，PPT 里标了【待确认】。

【若被问】孔径为什么建议 5–6 cm?

孔径越大角分辨率越好，但混叠频率越低；5–6 cm 时混叠频率约 2.9–3.4 kHz，仍覆盖语音主要能量。Idiap 的 Pepper 机器人头阵列（5.8×6.9 cm）是同量级的公开先例。这是建议值。

【若被问】3 麦和 4 麦精度差多少?

仿真里单声源精度接近（累积 2.5 s 时平均误差都在 2–10°），4 麦胜在多声源和 4 通道 SELD 生态；详见第 9 页。

P8 测向算法选型矩阵

讲稿 SRP-PHAT 免训练、开销低、可直接复现，作基线。MUSIC 理论分辨率高，但对相干反射敏感，家里混响重，只作对照。Cross3D-Edge 是 SRP 图加裁剪 3D CNN，在树莓派 4B 上 8.6 ms 一帧，鲁棒但只支持单声源。LightDOA 是双通道轻量网络，只覆盖 0–180°，适合 2 麦方案。主方案选轻量 SELD，因为它是唯一同时给出事件类别和方向的，正好用于决定该不该转。FN-SSL 和 IPDnet

精度强、面向移动声源，但开销较高，作为精度参照或蒸馏的教师模型。评级需在统一测试矩阵上复测。

【若被问】为什么不用 MUSIC?

家庭混响下反射与直达声高度相干，协方差矩阵出现秩亏，子空间分解会失效，需要空间平滑等额外处理；而且 4 麦最多分辨 3 个源，逐频点特征分解的计算量也比 SRP 大。

【若被问】为什么不直接用 FN-SSL/IPDnet?

它们针对移动声源和强混响，精度很好，代码开源；但网络以逐频点循环层为主，常开端侧运行代价较高（需实测确认）。更合适的用法是作为教师模型，把能力蒸馏给轻量 SELD。

【若被问】ACCDOA / Multi-ACCDOA / ADPIT 是什么?

ACCDOA：每个类别输出一个方向向量，向量方向就是声源方向，向量长度表示该类别是否活跃，把检测和定位合成一个回归目标。Multi-ACCDOA：每个类别有多条“轨道”，可以表示同一类的多个声源。ADPIT：训练时按最优排列计算损失，解决同类多声源谁对应哪条轨道的问题。

【若被问】SALSA-Lite 是什么?

多通道对数线性谱 + 归一化的通道间相位差（IPD 除以频率），只在混叠频率以下计算。比 SALSA 快约 30 倍，在 TAU-NIGENS 2021 上明显优于对数梅尔谱 + GCC 的传统特征。作者包括 NTU 甘文生（Woon-Seng Gan）教授团队。

【若被问】Neural-SRP 为什么没进主表?

它的优势是适配任意阵列几何、因果可实时，适合一个算法覆盖多款硬件；如果后续产品线有多种阵列，再引入。

P9 初步仿真：静态测向

讲稿 这是用镜像源法做的初步仿真：150 个随机房间、4 档混响，比较同孔径（约 5.7 cm）的 2、3、4 麦阵列跑 SRP-PHAT 基线。下面两张曲线是累积 2.5 秒语音的结果：3 麦和 4 麦很接近，平均误差约 2 到 10 度，基本没有粗大错误；2 麦因为前后镜像，37% 到 61% 是粗大错误。上面是单帧（32 毫秒）的空间谱：混响越强峰越宽，单帧误差小于 10 度的比例从 100% 掉到 18%。所以难点不是长时间累积后的精度，而是短时间窗加混响——响应要快就只能用很短的数据，这正是 M1 要解决的。

【若被问】为什么 3 麦和 4 麦差不多?

单声源时，同孔径下 3 麦已经能无歧义覆盖 360°，精度主要由孔径和混响决定；4 麦的优势在多声源（子空间法上限 M−1）和兼容 4 通道 SELD 网络。成本敏感时 3 麦可以接受。

【若被问】仿真可信吗?

镜像源法只模拟鞋盒房间的镜面反射，没有家具散射、真实噪声和麦克风失配，结果偏乐观；定性结论（2 麦镜像、单帧受混响影响大）是稳的，定量数字要在 RealMAN 子阵和设备实录上复核。

【若被问】SNR 15 dB 怎么设的?

按麦克风信号的总功率加白噪声。一个细节：TTS 语音带直流偏置，经过混响房间会被放大、虚高总功率，导致实际信噪比偏低，所以所有仿真先做 100 Hz 高通去直流。

P10 原型架构

讲稿 上一行是感知：4 麦 16 kHz、2 s 环形缓存；唤醒给出起止时间；取唤醒词片段做 PHAT 加权互谱，SRP-PHAT + 起始段加权测向；每 100 ms 输出方位和置信度。下一行是执行：换算到世界坐标、跟踪、决策，云台转向和波束对准，再交给视觉。原型不再需要事件分类网络，网络放到 Q1 提升短时精度。

【若被问】算力够吗?

SRP-PHAT 4 麦每帧 6 对 × 119 频点 × 360 方向的复数乘加，用 5° 网格可降到 72 方向；唤醒词片段测向只在触发时算一次，持续跟踪每 100 ms 一次，压力不大。具体在目标芯片上实测。

P11 波束成形对测向的要求

讲稿 我算了延迟求和波束在测向有误差时的语音增益损失：4 麦方阵误差 10° 只损失约 0.1 dB，20° 约 0.4 dB，所以 ±10° 足够。真正的瓶颈是小孔径：1 kHz 以下延迟求和几乎没有指向性，需要超指向或 MVDR 一类方法，这类方法对方向误差更敏感（判断，待仿真），所以定位要给置信度，低置信度时保持方向或退回宽波束。波束成形算法由谁做待确认，我先把接口和精度要求定下来。

【若被问】MVDR 为什么对方向误差敏感?

MVDR 在保证“指定方向”增益为 1 的前提下压低其他方向；如果指定方向偏了，真实的人声会被当成干扰压掉（目标自消）。常用对角加载、扩大约束区域来缓解。

【若被问】波束成形要你来做吗?

mentor 只说场景涉及三个技术，没有明确分工；我先保证定位输出满足波束成形的需要，具体谁做在第一次周会确认。

P12 持续跟踪与云台控制

讲稿 跟踪器一期用圆周卡尔曼，状态是方位和角速度，要处理 0/360° 回绕；三期换粒子滤波，直接用 SRP 或网络输出当似然，能处理多峰和伪峰，也方便接入视觉。多目标 GM-PHD 先预研。右边状态机：待机、触发确认、转向、视觉确认、跟踪、静音保持；转向时冻结测向；丢失目标先保持航迹，超时再回预置位。左下四条规则，重点是死区防抖、优先级，以及用干扰方向表处理电视。

【若被问】圆周卡尔曼怎么处理 359° 到 1°?

计算新息（观测减预测）时把角度差回绕到 (−180°, 180°]，状态更新后再取模到 [0°, 360°)。

【若被问】干扰方向表会不会把真人也屏蔽了?

只有“长时间固定方向 + 视觉无人形”同时满足才记入；有人出现在该方向、或出现哭声/呼救等高优先级事件时不受屏蔽。

【若被问】N 帧取多少?

需要在误转率和响应时延之间折中，例如 100 ms 一帧取 2–3 帧对应 0.2–0.3 s，作为 B0 的调参项。

P13 仿真示意：跟踪

讲稿 说话人绕摄像头走一段弧线，6 到 7.5 秒叠加云台电机噪声。蓝点是每 100 毫秒的原始测向，平均误差约 22 度、有语音时约 14% 是粗大错误；绿线是圆周卡尔曼输出，用“6 中取 3”起始、±30 度门控和静音保持，平均误差约 6 度。红叉是电机期间的测向，几乎都指向电机方向，平均误差约 160 度，所以必须冻结。

【若被问】“6 中取 3”是什么?

航迹起始规则：最近 6 个观测里有 3 个落在 ±10° 内才起始，比“连续 3 帧一致”更能容忍偶发野值，又不会被单个野值骗走。

【若被问】为什么电机噪声会把测向拉过去?

电机就在阵列旁边，是近场强声源，能量比语音高，SRP 峰自然指向它。

P14 闭环仿真

讲稿 把 B0 全链路串起来：说话人在画面外开口，边说边绕行 170 度。状态条显示：待机，0.29 秒后开始转向，转动中冻结测向，到位后视觉确认，进入跟踪。之后目标 99% 时间在画面中央一半，17 秒云台只动 10 次，融合视觉后误差约 1.3 度。这是理想场景：单声源、无电视、视觉为模拟。

【若被问】0.29 秒是从什么时候算的?

从 L0 触发（检测到声音）算起；触发本身在语音开始后约一个块（0.1 s）内。

【若被问】为什么云台是一步一步走的?

死区设计：目标偏离画面中心小于 15° 不动，超出才重新居中，避免持续抖动，和 Echo Show 10 的分区思路一致。

P15 电视干扰仿真

讲稿 电视在画面里一直放人声，但画面里没有人；12 秒后真人在画面外开口。不启用干扰方向表：跟踪器锁在电视上，真人方向的观测被门控当成野值拒掉，云台始终不转。启用后：跟踪目标“画面内、有声、无人”累计 4 秒，就屏蔽该方向并释放航迹，真人开口 3 秒内入画。之后若在该方向看到真人，自动解除屏蔽。

【若被问】4 秒会不会太短，把真人也屏蔽了?

演示用 4 秒，产品里要更长（如 20 秒以上），并且只要视觉看到人就立即解除。具体阈值要在真实家庭数据上调。

【若被问】电视在画面外怎么办?

画面外没有视觉线索，只能先转过去看；看到“有声无人”后再记入干扰表。也可以让用户在 App 里标注电视位置，类似 Echo Show 10 划定运动范围。

P16 视听融合

讲稿 视场外只有声学，负责 360° 找人；视场内由视觉精定位。三个要点：坐标统一，把像素横坐标用相机内参换算成方位，加上云台角，和声学方位放在同一世界坐标比对，需要做一次阵列与相机的外参标定；说话人确认，多人时用 Light-ASD 判断谁在说话，约 1 M 参数、0.6 GFLOPs；融合跟踪，用粒子滤波把两路似然相乘，CAV3D 正好是摄像头和麦阵共址的数据集。DCASE 2025 也新增了画面内外判定。

【若被问】标定怎么做?

把音箱放在画面中不同位置播放，同时记录检测框中心的像素坐标和声学测得的方位，拟合两者之间的角度偏置即可。

【若被问】Light-ASD 需要什么输入?

人脸序列 + 对应时段的音频，判断这张脸是否正在说话；在 AVA-ActiveSpeaker 上 mAP 94.1%。它解决的是“画面里谁在说”，和麦阵测向互补。

【若被问】这和“视觉声源定位”是一回事吗?

不是。视觉声源定位通常用单声道音频在图像里找发声物体，没有空间信息；本方案用麦阵测方位，视觉只用于视场内确认与精定位。

P17 前沿趋势

讲稿 按对我们的可用时间排序。近期可用：DCASE 2025 改成立体声加普通视角视频并加入画面内外判定，和我们的场景几乎一样；RealMAN 证明真实数据训练优于仿真、能训练可变阵列网络；

Cross3D-Edge 和 LightDOA 说明常开测向的算力已可行。中期：DCASE 2026 转向声学成像，6 月已结束，8 支队伍 29 个提交，评测只给 4 通道音频，纯音频第一名（港中文）Mask mAP 仅 0.108——4 通道能做但精度尚低。远期：空间音频加大模型（BAT、ELSA），支持语义查询。

【若被问】DCASE 2026 的结果说明什么?

评测输入只有 4 通道四面体阵列，和我们的小阵列同量级，说明“少通道做声学成像”是学术界的正式课题；但第一名 Mask mAP 只有 0.108，离产品可用还远，所以放在中期储备。

【若被问】声学成像和我们现在做的有什么区别?

现在输出“一个方向”，声学成像输出“一张声能分布图”并标注发声物体，可以直接叠加在视频画面上。

【若被问】大模型方向现在能用吗?

不能直接上端侧：BAT 用的是 7B 的 LLaMA-2。现阶段作为远期储备，关注其空间音频编码器部分。

P18 公开数据集

讲稿 按贴近程度排序，前三个最贴近：CAV3D 是摄像头与 8 麦圆阵共址，有出入画面、长时间静音等情况，最适合评测视听跟踪；RealMAN 是 NeurIPS 2024 真实录制数据，32 麦，可以抽取与产品几何接近的子阵，还有 144 h 真实噪声，作者实验中真实数据训练优于仿真训练，CC BY 4.0；SSLR 是 Pepper 机器人头 4 麦，约 6 cm，带风扇自噪声，和摄像头的小阵列加自噪声很像，但只能非商用。LOCATA 有移动阵列任务，可近似云台转动。STARSS23 和 DCASE 2025 立体声版用于事件加定位联合评测。非商用数据只做研究对比。

【若被问】为什么不用 STARSS23 当主训练集?

它的四面体阵列几何与产品不同，SELD 网络的空间特征对几何敏感，直接迁移效果差；它更适合做方法对标和评测。训练主体靠按产品几何的仿真。

【若被问】LOCATA 移动阵列和云台转动一样吗?

近似但不同：LOCATA 是人带着阵列移动，云台是绕固定轴旋转。共同点是都要处理阵列运动和坐标变换，所以可以用来验证这部分逻辑。

【若被问】CAV3D 的许可?

官网需申请获取，具体条款没查到，PPT 写的是“见官网”，用前要确认。

P19 数据方案

讲稿 分三步。仿真是训练主体：按产品阵列几何生成，房间、混响、距离、轨迹、干扰、信噪比都按家庭场景设范围，还要做阵元位置扰动和通道失配增强，让模型对硬件误差不敏感；对称阵列可用通道置换做旋转增强。第二步用 RealMAN 等真实数据微调。第三步自采数据是最终验收依据：按房间、方位、距离、干扰条件正交采集，单独录长时间无人加电视的音频，专测误转率。

【若被问】仿真要做多少小时?

建议先做几十小时验证管线和训练流程，再根据真实集上的效果决定是否扩充；关键是声学多样性（房间、混响、干扰），而不是单纯时长。SpatialScaper 论文显示性能随声学多样性提升。

【若被问】gpuRIR 怎么做移动声源?

对轨迹上每个点生成 RIR，再用重叠相加把源信号分段卷积（simulateTrajectory 函数），GPU 加速约百倍于 CPU。

【若被问】FSD50K 能商用吗?

它按片段分别使用 CC0、CC-BY、CC-BY-NC 等许可，需要按许可筛掉非商用片段后才能用于产品训练。

P20 评测方案

讲稿 评测分三层。帧级看 MAE、命中率和粗大错误率，事件加定位用 DCASE 的 SELD 指标；轨迹层看跟踪误差、断裂和多人 ID 切换，参考 LOCATA；系统层看产品体验：转向命中率、响应时延、误转率和端侧开销。所有方案在同一测试矩阵上逐格对比，用数据决定是否进入下一阶段。

【若被问】F1@20°、LE_CD、LR_CD 是什么?

F1@20°：类别正确且方向误差小于 20° 才算检测正确；LE_CD：类别正确时的平均定位误差；LR_CD：类别正确时的定位召回率。均为 DCASE SELD 常用指标。

【若被问】测试矩阵组合太多怎么办?

仿真上可以全跑；自采数据按关键组合抽样（例如 RT60 中档 × 三种 SNR × 电机两档），优先覆盖产品最常见场景。

P21 demo 方案

讲稿 分两档：A 离线回放，11 月第 2 周起每周可演示，用多通道录音和唤醒时间戳跑测向、跟踪和云台状态机，画方位曲线和俯视图，给误差和时延统计；B 实时演示，12 月中旬，需要目标阵列或 4 麦 USB 阵列，唤醒先用 mentor 模块或按键模拟，屏幕显示方位、虚拟或真实云台转向。五个固定场景每周复测。

【若被问】硬件没到怎么办?

离线 demo 不依赖硬件，用仿真和公开数据（LOCATA）即可；实时 demo 可以先用通用 4 麦 USB 阵列，接口按目标阵列写，换硬件只改几何参数。

【若被问】为什么固定五个场景?

覆盖正前方、360°、移动、电视干扰、两人这五类关键情况；固定后每周只换算法版本，进展和退化都一眼看得出来。

P22 12 月底原型周计划

讲稿 按实际投入排：11 月每周 2 天（6 天）做离线——对齐接口、离线 demo、录音方案；12 月全职（约 22 天）做实时与集成——实录调参、实时框架、接唤醒与波束成形接口、鲁棒性、冻结原型。风险都有预案。

【若被问】周期怎么估的?

按实际投入：11 月每周 2 天、12 月全职，约 28 个工作日；11 月离线部分已有仿真和基线代码打底，所以够用。

P23 首次周会要对齐的六件事

讲稿 最急的三件：demo 用哪块阵列或板子；唤醒跑在单通道还是多波束、能否给唤醒词起止时间和置信度；波束成形由谁负责、需要定位输出什么。另外三件：芯片预算、镜头和云台参数、实录数据与周会形式。

四、竞品 PPT 讲稿要点

C1 封面 竞品调研覆盖四类：家用云台摄像头、智能屏与家庭机器人、会议摄像头、芯片与算法方案；每条信息标了证据等级。

C2 四个发现 ① 家用摄像头听声转向仍是少数；② 成熟产品都是声学粗定位 + 视觉确认；③ 反射误转是公认痛点；④ 定位能力在下沉到芯片（第 ④ 条后半是判断）。

C3 范围与方法 四类产品 + 证据等级 A/B/C 的定义。

C4 产品一览①（家用） 每个竞品一张官方图 + 三条要点 + 证据等级 + 可点击来源。重点讲雀蛋 Pro：2025 年发布，双麦，“海雀海雀”唤醒后转向说话人，评测称正面 180° 内识别——和我们“2 麦只能测 0–180°”的仿真结论一致。

C5 产品一览②（会议 / 芯片） 会议设备都是多麦 + 视觉确认，已按现行型号更新：Cisco 现行 Quad Camera 内置 8 麦阵列、只用于 SpeakerTrack（前代 SpeakerTrack 60 已下线）；Owl 已到

Meeting Owl 4+（2024，8 麦 + 视觉 / 声音 / 动作聚焦）；IdeaHub ES2 Plus 12 麦、12 m 拾音，B3 数据表直接写“发言人跟踪 = 智能声源定位”；XMOS 把测向做进芯片。

C6 家用云台摄像头 萤石 C6C 无极巡航版 2019 年已有 3 麦 360° 声源定位（官方资讯）；海雀 Pro 只有电商页宣传（C）；Tapo、小米等是声音告警 + 视觉追踪。启示：做好“稳、不乱转”就是差异化。

C7 Echo Show 10 拆解 全部来自 Amazon Science 官方博客：声学 + 视觉融合、波束选择不适合驱动转动、用户划定运动范围抗反射、死区 / 保持区 / 运动区、≤180°/s、端侧处理；右列逐条对应我们的设计。注意它已停产（零售商 / iFixit），我们拿它当“技术参照”而不是“市场标杆”。

C8 会议摄像头 Cisco 的专用跟踪阵列 + 人脸确认 + 双摄预对准最典型；共性是多麦大孔径、视觉确认、平滑切换。IdeaHub 是华为自己的产品，可内部请教。

C9 芯片与方案 AZ1 端侧跑声学 + 视觉；XMOS XVF3800 内置测向（扫描波束 + 跟踪波束）；IPC SoC 厂商公开资料未见此能力（待内部确认）。

C10 定位矩阵 横轴声学作用、纵轴视觉作用；家用产品在中间偏下，融合跟踪在右上角；我们的目标是用家用成本做到右上角。

C11 痛点与对策 反射误转、多人噪声、自身回放、转动抖动、隐私——每条都有公开证据和对应对策。

C12 启示 六条：差异化、视听融合路线、体验设计、安防价值（Astro 订阅）、隐私功耗、内部协同。

C13 下一步 竞品实测：统一测试矩阵测命中率、时延、误转率，得到竞品基线后再定 KPI；另可补专利检索与用户评价挖掘。

C14 资料来源 按证据等级列出，被问出处时直接指过去。

【若被问】海雀 / 雀蛋 Pro 是华为智选的产品，为什么证据等级是 C?

公开渠道只找到电商商品页、发布会报道和体验文章，没有官方技术参数；如果组里能拿到内部资料，可以升级为 A。雀蛋 Pro 双麦宣称正面 180°，正好可以作为我们 2 麦分析的旁证。

【若被问】Echo Show 10 已经停产，还拿来对标合适吗?

它是唯一公开了完整工程细节（声学 + 视觉融合、分区运动、端侧处理）的家用“会转”设备，作为技术参照仍然最好。停产本身也是信号：带电机转屏的智能屏没有延续下去，而云台摄像头本来就会转，是成熟品类，商业风险不同——这一点是我的判断。

【若被问】竞品型号是最新的吗?

截至 2026-11 公开资料：会议设备已更新为现行型号（Cisco Quad Camera、Meeting Owl 4+），小米换成 C700（2024），Echo Show 10 标注已停产；萤石 2019 年的 C6C 无极巡航版

是官方资料里最明确的声源定位型号，有第三方文章称新款 C6c 800 万也支持声源定位，但未在官网核实。

【若被问】图片能直接用吗?

图片来自各厂商官网或发布会报道，每张都标了来源，只在内部调研材料里使用；对外发布前要替换或取得授权。

【若被问】萤石的数据是 2019 年的，会不会过时?

是 2019 年的官方资讯，说明这个功能早就有；后续型号是否保留需要查当前官网，PPT 里已注明以官方最新说明为准。

五、基线代码包与仿真说明

代码在 code\ssl_baseline，README 里有目录、运行命令和全部结果。下面是需要你自己理解、能讲清楚的部分：

模块	做了什么	能回答的问题
doa.py	SRP-PHAT；置信度用归一化峰值（空间相干度，理想平面波 = 1）；起始段加权；抛物线插值	为什么不用 (峰值−均值)/标准差：小孔径阵列主瓣很宽，这个指标不敏感
trigger.py	能量 + 谱通量的 L0 常开触发，自适应噪声底	开机就有电视时噪声底会被初始化到电视电平，产品里要用最小值统计
tracker.py	圆周卡尔曼（方位 + 角速度）、±30° 门控、3 s 静音保持、6 中取 3 起始	359°→1° 怎么处理：新息回绕到 (−180°, 180°]
ptz.py	状态机：待机 / 转向 / 视觉确认 / 跟踪 / 静音保持；死区 ±15°；电机门控；干扰方向表	干扰表用“跟踪目标在画面内、无人”计时，而不是用原始测向（原始测向太散，计不满）
sim.py	pyroomacoustics 静止 / 移动声源，近场电机噪声，高通去直流	移动声源怎么仿真：分块算 RIR，汉宁窗 50% 重叠相加

起始段加权的效果（1 s 语音、100 个随机房间、4 麦）

RT60	SRP-PHAT：MAE / Acc@10° / 粗大错误	+ 起始段加权
0.4 s	5.6° / 88% / 0%	5.0° / 89% / 0%
0.6 s	9.2° / 64% / 0%	7.6° / 69% / 0%
0.8 s	12.9° / 54% / 4%	8.5° / 69% / 1%

原理：优先效应——每个音节的起始段以直达声为主，反射还没到；给能量上升的帧更大权重，就相当于“只听直达声”。这是一个零训练成本的改进，可以写进 B0。

仿真里踩过的坑（可以作为“严谨性”的例子讲）

- **直流偏置：**TTS 语音带直流，经混响房间（RIR 直流增益大）后虚高总功率，按总功率加的噪声就偏大，测向结果被严重低估（4 麦 RT60 0.6 s 的平均误差从 6° 被算成 15°）。加 100 Hz 高通后修正。启示：真实录音也要先去直流。
- **跟踪起始：**最初用“第一个观测就起始”，碰上野值会锁死；改成 6 中取 3 后稳定。
- **干扰表计时：**最初按原始测向分箱计时，原始测向太散、计不满；改为按跟踪目标方向计时后生效。

六、原调研 PPT 核对清单（供参考，改不改由你决定）

以下是联网核对原 PPT 时发现的可以更准确的地方，按优先级排序。建议以“补充更新”的方式修改，不必逐条指出。

#	原 PPT 位置	原内容	核对结果与建议
1	阶段三（SELDnet 与损失函数）	2019 设立 SELD；2020 移动声源；2021 未知干扰；2024 音视频 + 测距	视听赛道从 2023 开始（STARSS23），2024 加入距离估计；可补：2022 改用真实录音（STARSS22），2025 立体声 + 画面内/外判定，2026 转向声学成像（STAIRS26，32 通道）
2	阶段五（端侧轻量化）	LightDOA 与“LLM 辅助数据合成”列为两项	两者出自同一篇论文：Li 等，arXiv 2511.08012（2025-11，预印本）。LightDOA 为双通道输入、0–180° 按 5° 分为 37 类；“精度媲美 CRNN 等”为作者自报
3	阶段五 Cross3D-Edge	127.1 MFLOPS，4B 实测提速 7.26 倍	数字核对无误。“4B”指树莓派 4B，8.59 ms/帧；出处 Yin & Verhelst，ACM TECS 2023（arXiv 2503.02046）
4	阶段五 量化误差专项研究	未给论文	没有查到对应出处，建议补论文名，或删去
5	阶段三 ACCDOA	标注 2020	论文发表于 ICASSP 2021（arXiv 2020-10）；Multi-ACCDOA + ADPIT 为 ICASSP 2022
6	阶段四 SELD-TCN	放在 2021–2023 阶段	论文为 EUSIPCO 2020（Guirguis 等，Bosch + 斯图加特大学），时间略早于该阶段
7	代表企业 Amazon	SRP-PHAT + Delay-and-Sum（经典方案）；专利 US9129223B1	专利核对无误（2015 授权，“Sound localization with artificial neural network”，原受让人 Rawles LLC，后归 Amazon）；“Echo 用 SRP-PHAT + DS”未找到公开出

			处，建议加“业内常见方案”之类的限定
8	场景一 代表产品	萤石 C6 系列、华为智选海雀 Pro	更准确：萤石 C6C 无极巡航版（官方资讯提到声源追踪 + 人形追踪）；海雀 Pro 的声源定位来自电商商品页宣传，无官方参数
9	各场景 功耗与 BOM 增量	0.5–1.5 W、15–40 元等	没有找到公开出处，建议标注“估算”

七、关键概念速查

概念	一句话解释
TDOA / GCC-PHAT	两个麦克风的到达时间差；GCC-PHAT 用相位变换加权的互相关求时延，θ = arcsin(cτ/d)
SRP-PHAT	对每个候选方向，把所有麦克风对在该方向对应时延上的 GCC-PHAT 值相加，取能量最大的方向
空间混叠	间距超过半波长时相位差重复、角度歧义；临界频率 f = c/(2d)
IPD / DP-IPD	通道间相位差；DP-IPD 指只由直达声决定的相位差，FN-SSL/IPDnet 的学习目标
SELD	声音事件检测 + 定位：同时输出类别、起止时间和方向
ACCDOA	每个类别一个方向向量，长度表示活跃度、方向表示方位，检测与定位合一
Multi-ACCDOA / ADPIT	每类多条轨道以表示同类多声源；ADPIT 按最优排列算损失
SALSA-Lite	多通道对数线性谱 + 归一化 IPD（混叠频率以下），为实时 SELD 设计
RT60	混响时间：声能衰减 60 dB 所需时间，家庭房间通常约 0.3–0.6 s
圆周卡尔曼	对角度量做卡尔曼滤波，并处理 0/360° 回绕
粒子滤波	用一组带权重的样本近似目标位置分布，适合多峰、非线性、多传感器融合
ASD（说话人检测）	判断画面中某张脸此刻是否在说话，如 Light-ASD

配图：两个最常被问的原理

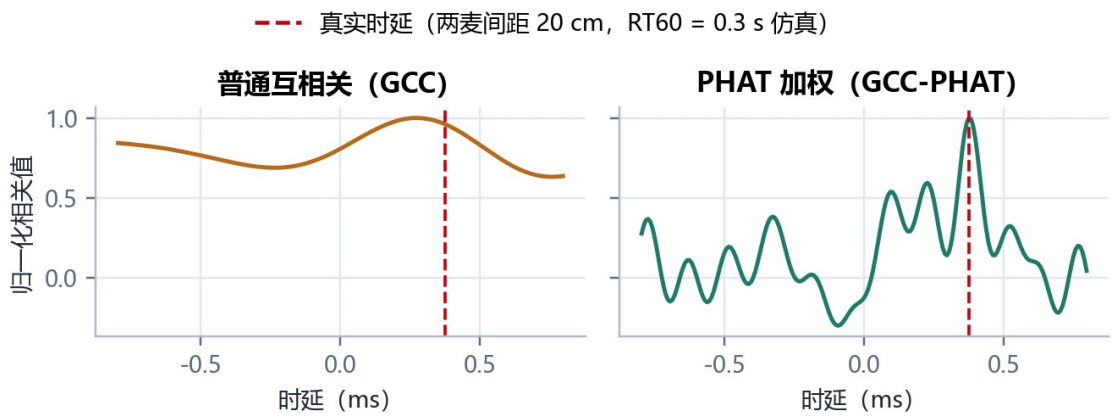


图 1　GCC 与 GCC-PHAT：普通互相关的峰又宽又偏（语音低频能量大），PHAT 只保留相位后，峰尖锐且落在真实时延上。



图 2　空间混叠：4 麦方阵（相邻间距 4 cm）的波束图。1 kHz 主瓣很宽；3 kHz 变窄；6 kHz 超过混叠频率（约 4.3 kHz），出现多个等高的栅瓣，无法分辨方向。

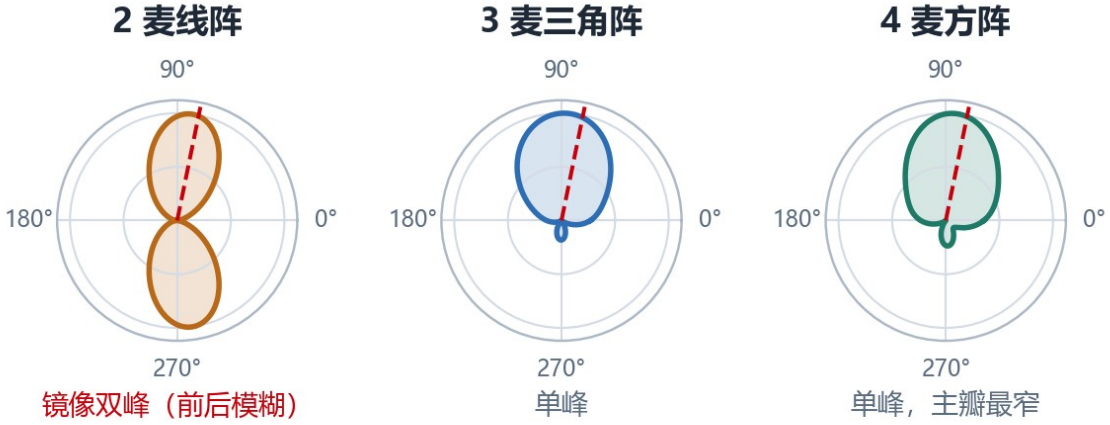


图 3　同一声源下 2 / 3 / 4 麦的 SRP-PHAT 空间谱：2 麦出现关于阵列轴对称的镜像双峰。

八、向 mentor 确认的问题（可直接照问）

- 阵列：产品上麦克风有几个、间距多少？装在底座还是云台头上？
- 芯片：目标是哪颗 SoC？NPU/DSP 给声学算法的算力、内存和常开功耗预算大概多少？
- 镜头与云台：水平视场角多少？云台转速和电机噪声有没有数据？
- 声音类别：除了人声，哪些声音需要触发转向（哭声、玻璃破碎、报警音……）？优先级怎么排？
- 场景范围：要不要俯仰角和距离？多人同时说话要不要考虑？
- 数据：能不能用设备采实录？组里有没有已有的录音或 RIR？公开数据集在许可上有什么要求？

提问方式建议：先讲完 P2 结论，再翻到 P20 说“这六项确认后，我就能把建议值定下来进入基线开发”，显得是在推进而不是在要信息。

九、参考文献与出处

测向与 SELD 方法

- Chakrabarty & Habets. Broadband DOA estimation using convolutional neural networks trained with noise signals. WASPAA 2017.
- Adavanne et al. Sound event localization and detection of overlapping sources using convolutional recurrent neural networks. IEEE JSTSP 2019.
- Shimada et al. ACCDOA. ICASSP 2021；Shimada et al. Multi-ACCDOA (ADPIT). ICASSP 2022.
- Nguyen, Jones, Watcharasupat, Phan, Gan. SALSA-Lite. ICASSP 2022. arxiv.org/abs/2111.08192
- Guirguis et al. SELD-TCN. EUSIPCO 2020.
- Diaz-Guerra, Miguel, Beltran. Robust sound source tracking using SRP-PHAT and 3D CNNs (Cross3D). IEEE/ACM TASLP 2021.
- Yin & Verhelst. CNN-based robust sound source localization with SRP-PHAT for the extreme edge (Cross3D-Edge). ACM TECS 2023. arxiv.org/abs/2503.02046
- Li et al. DOA estimation with lightweight network on LLM-aided simulated acoustic scenes (LightDOA). arXiv 2511.08012, 2025.
- Wang, Yang, Li. FN-SSL. Interspeech 2023；IPDnet, arXiv 2405.07021, 2024. github.com/Audio-WestlakeU/FN-SSL
- Grinstein et al. The Neural-SRP method for universal robust multi-source tracking. IEEE OJSP 2024.

- Ma, May, Brown. Exploiting deep neural networks and head movements for robust binaural localization of multiple sources in reverberant environments. IEEE/ACM TASLP 2017.
- He, Motlicek, Odobez. Deep neural networks for multiple speaker detection and localization (SSLR). ICRA 2018. arxiv.org/abs/1711.11565

视听融合

- Liao et al. A light weight model for active speaker detection (Light-ASD). CVPR 2023. github.com/Junhua-Liao/Light-ASD
- Qian et al. Multi-speaker tracking from an audio-visual sensing device (CAV3D / AV3T). IEEE TMM 2019. speechtek.fbk.eu/cav3d-dataset
- Zhao et al. Audio-visual speaker tracking: progress, challenges, and future directions. arXiv 2310.14778.
- STNet: Deep audio-visual fusion network for robust speaker tracking. arXiv 2410.05964, 2024.
- Stereo SELD with onscreen/offscreen classification (DCASE 2025 Task 3 baseline). arXiv 2507.12042.

数据集与工具

- Evers et al. The LOCATA challenge: acoustic source localization and tracking. IEEE/ACM TASLP 2020. locata.lms.tf.fau.de
- Yang et al. RealMAN. NeurIPS 2024 Datasets & Benchmarks. github.com/Audio-WestlakeU/RealMAN（CC BY 4.0）
- Shimada et al. STARSS23. NeurIPS 2023 Datasets & Benchmarks. zenodo.org/records/7880637（MIT）
- DCASE2025 Task 3 Stereo SELD Dataset. zenodo.org/records/15559774
- STAIRS26（DCASE 2026 Task 3 开发集，32 通道 Eigenmike，声学成像标注）. zenodo.org/records/18171005（MIT）
- Lathoud, Odobez, Gatica-Perez. AV16.3. MLMI 2004. idiap.ch/dataset/av16-3（EULA 非商用）
- Idiap SSLR. idiap.ch/dataset/sslr（EULA 非商用）
- Strauss et al. DREGON: dataset and methods for UAV-embedded sound source localization. IROS 2018.

- Roman et al. SpatialScaper. ICASSP 2024. github.com/iranroman/SpatialScaper
- Diaz-Guerra et al. gpuRIR. github.com/DavidDiazGuerra/gpuRIR
- Scheibler et al. Pyroomacoustics. ICASSP 2018（DOA 模块含 SRP、MUSIC、NormMUSIC、CSSM、WAVES、TOPS、FRIDA）

竞品（补充）

- Amazon Science. The science behind Echo Show 10. amazon.science/blog/the-science-behind-echo-show-10
- 萤石官方资讯 2019-04-02：C6C 无极巡航版 3 麦 360° 声源定位. ezviz.com/cn/news/2342.html
- XMOS XVF3800 文档：Voice Processing Pipeline. xmos.com/documentation
- Cisco TelePresence SpeakerTrack 60 产品资料；Logitech RightSight 2 发布（2022-02-01）；Jabra PanaCast 50 官网；华为 IdeaHub 新闻稿
- Zheng et al. BAT. ICML 2024. arxiv.org/abs/2402.01591；Devnani et al. ELSA. NeurIPS 2024

产品与专利

- 萤石官方资讯：C6C 无极巡航版“巡航追踪、声源追踪、人形追踪”. ezviz.com/cn/news
- 华为智选海雀智能摄像头 Pro 系列：京东商品页宣传声源定位与语音控制云台（非官方参数）
- US 9,129,223 B1. Sound localization with artificial neural network. 2015.