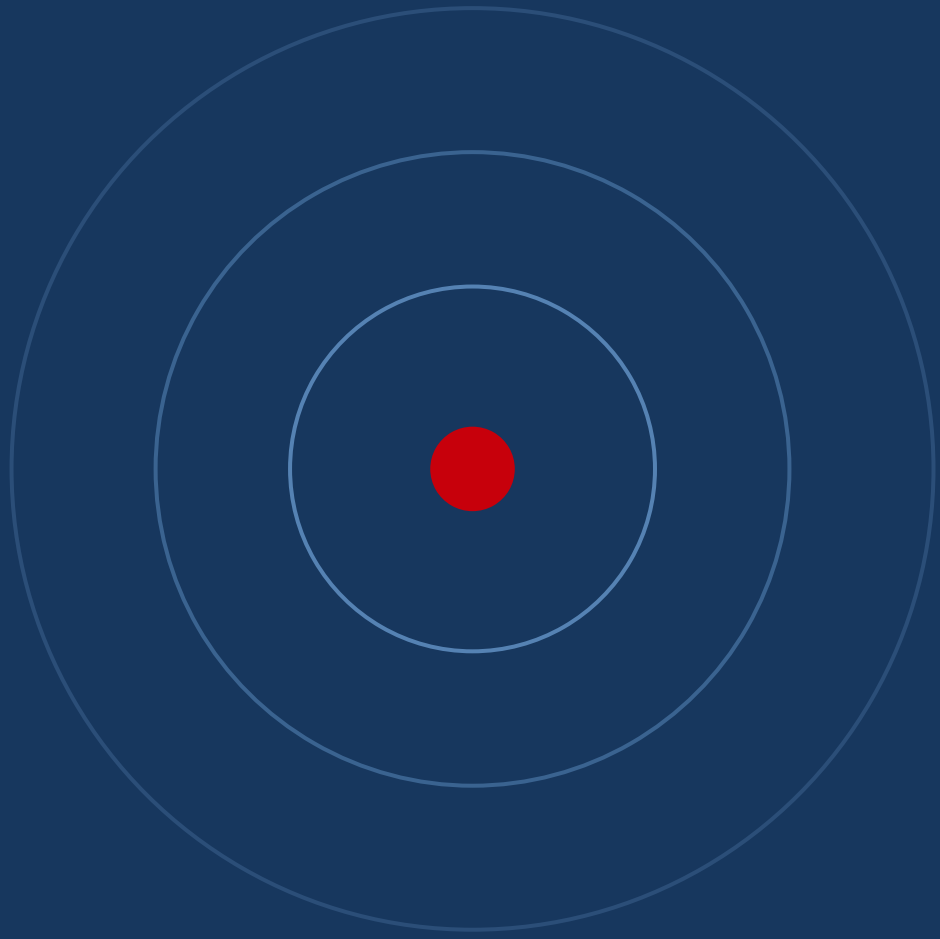
声源定位（SSL） · 场景一：摄像头转向说话人

训练数据方案与采集计划

数据集选型 · 仿真方案 · 自采集方案 · 时间计划 · 对比规范



汇报人：令狐雅熙

2026.11

结论：仿真打底、真实数据微调、自采数据测试；公开数据按用途选型

公开数据的阵列几何都与目标设备不同；自采是关键路径，需在 11 月下旬定稿方案

1 三类数据各司其职

仿真：按目标几何大规模生成，作训练打底；真实数据（RealMAN）：网络微调，缩小仿真与实录的差距；自采：最贴近设备，用于微调和最终测试

2 为什么必须有真实数据

RealMAN 实验（静止说话人，5° 内准确率）：只用仿真训练 60.4%，用真实数据训练 89.2%。仿真负责覆盖面，真实数据负责贴近实际

3 自采规模（建议）

4 类房间，每间约 4.4 h，共约 17.5 h；其中有效语音约 7.5 h，适合微调与测试，不足以单独训练

4 关键路径与依赖

11 月下旬方案定稿 → 12 月上中旬深圳准备与试录 → 12 月中旬至 1 月上旬采集 → 1 月中下旬交付；前置依赖为阵列 / 样机与录音合规流程

数据集选型：按用途分四类，每个数据集的许可都已按官方页面核实

绿色：可商用并采用；橙色：仅限研究；灰色：储备，暂不使用

评测

与文献对比、验证测向与跟踪

LOCATA （2018）
静态测向（Task 1）与跟踪（Task 3）评测，便于与文献对比
许可： ODC-BY

自采测试集
场景一 5 个演示场景、电视干扰
许可：自有

训练与微调

网络训练的真实数据

RealMAN （2024）
网络训练与微调的主力真实数据；抽取与目标几何接近的子阵
许可： CC BY 4.0

自采微调集
按目标设备微调
许可：自有

仿真素材

按目标几何生成仿真数据的输入

Treble10 （2025）
小阵列高逼真仿真，补充 pyroomacoustics
许可：冲激响应子集 CC BY-NC-SA 4.0； 6 通道语音子集 CC BY 4.0

AISHELL-1 （2017）
仿真用干净中文语音
许可： Apache 2.0

MUSAN （2015）
电视类干扰（音乐 + 语音节目）
许可： CC BY 4.0

DEMAND （2013）
多通道环境噪声
许可： CC BY 4.0

仅研究 / 储备

许可受限或几何差异大

MISP 2021 （2021）
家居 + 电视干扰场景的效果参考
许可：非商用协议（需签署）

STARSS23 （2023）
异响扩展；几何与目标设备差异大
许可： MIT

DCASE 2025 立体声 SELD （2025）
视听融合、画面内外判定
许可： MIT

SSLR （2018）
小孔径 + 自噪声，仅研究对比
许可：受限下载，条款需申请

CAV3D （2019）
视听跟踪评测
许可：需申请，条款未公开

数据集明细：年份、阵列、标注与许可（2026-11 按官方页面核实）

数据集	年份	阵列与场景	方位标注	规模	许可	结论与用途
RealMAN	2024	实录； 32 麦阵列，可抽小子阵；中文语音（音箱播放），32 个室内外场景，静止 + 移动	有：方位、俯仰、距离	语音 83.7 h + 噪声 144.5 h	CC BY 4.0	采用：网络训练与微调的主力真实数据；抽取与目标几何接近的子阵
LOCATA	2018	实录； 4 类阵列（含 12 麦机器人头、平面阵）；英语，单房间	有	6 个任务，规模小	ODC-BY	采用：静态测向（Task 1）与跟踪（Task 3）评测，便于与文献对比
Treble10	2025	物理精确仿真；含 6 麦圆阵（半径 3 cm）设备冲激响应；10 个带家具的真实房间	有（几何已知）	3000+ 条冲激响应	冲激响应子集 CC BY-NC-SA 4.0； 6 通道语音子集 CC BY 4.0	采用 6 通道语音子集：小阵列高逼真仿真，补充 pyroomacoustics
AISHELL-1	2017	单通道近讲；中文， 400 人	无	约 178 h	Apache 2.0	采用：仿真用干净中文语音
MUSAN	2015	单通道；音乐、语音、噪声三类	无	音乐 / 语音 / 噪声	CC BY 4.0	采用：电视类干扰（音乐 + 语音节目）
DEMAND	2013	多通道实录环境噪声（家居、办公、交通等）	无	多种环境	CC BY 4.0	采用：多通道环境噪声
MISP 2021	2021	实录；远 / 中 / 近场麦克风 + 摄像机；中文对话， 34 个真实家庭电视房间	无直接方位标注（有视频）	141 h 音视频	非商用协议（需签署）	仅研究：家居 + 电视干扰场景的效果参考
STARSS23	2023	实录； 4 通道四面体阵列 / FOA； 13 类声音事件， 16 个房间	有（事件级）	约 7.5 h	MIT	储备：异响扩展；几何与目标设备差异大
DCASE 2025 立体声 SELD	2025	由 STARSS23 转换：双通道 + 普通视角视频，含画面内 / 外标签	有	13 类声音事件	MIT	储备：视听融合、画面内外判定
SSLR	2018	实录； Pepper 机器人头 4 麦，含风扇自噪声	有	约 25 h	受限下载，条款需申请	储备：小孔径 + 自噪声，仅研究对比
CAV3D	2019	实录； 8 麦圆阵与摄像头共址	有	20 段序列	需申请，条款未公开	储备：视听跟踪评测

旧数据集（如 AISHELL-1 、 MUSAN ）只作语音和噪声素材，年份不影响使用；测向数据主要看阵列几何和场景是否贴近。

仿真方案：按目标几何生成约 200 h 作训练打底，现有脚本已覆盖主要场景

项目	建议设置
阵列	按目标设备几何（麦克风数量、间距、安装位置）；几何未定前先用 4 麦 5.7 cm 方阵
房间	边长 3–8 m； RT60 0.2–0.9 s；家具散射用随机吸声系数近似
声源	距离 0.5–5 m，方位 0–360°；静止 / 圆弧 / 直线 / 随机游走；唤醒词 + 连续语音
干扰	电视（语音、音乐节目）、空调 / 风扇扩散噪声、云台电机近场噪声； SIR −5 ～ 20 dB， SNR 0 ～ 30 dB
增强	阵元位置扰动、通道增益与相位失配、通道置换（对称阵列）
工具与规模	pyroomacoustics （现有脚本）、 gpuRIR （移动声源）； Treble10 6 通道语音子集作高逼真补充；目标约 200 h 多通道数据（建议值）

已有基础

- 镜像源法房间仿真（ pyroomacoustics ）
- 唤醒词 + 持续电视干扰
- 移动说话人（分块 RIR ）
- 云台电机近场噪声
- 100 Hz 高通去直流

注意

- 阵列几何未定前，仿真结论只能作方法比较
- 镜像源法缺少家具散射、麦克风失配，需用 RealMAN 与自采数据校准
- 200 h 为建议值，按模型规模调整

自采集方案（每间房）：音箱播放覆盖全网格，真人补充真实性，干扰单独录制便于按需混合

项目	声源与内容	点位 / 条数	单位时长	条件	说明
静态网格（音箱播放）	音箱播放：唤醒词 ×5 遍 + 连续语音约 20 s	12 方位 ×3 距离 ×2 高度 = 72 点	30 秒	安静	可重复、覆盖全；唤醒词先请多人近讲录制再播放
静态子集（真人）	真人：唤醒词 ×5 遍 + 指令与自由说话	4 人 ×12 方位 ×1 距离 =48 次	30 秒	安静	补充真人头部指向性、说话习惯
移动轨迹（真人）	真人边说边走：圆弧、直线、靠近 / 远离	4 人 ×10 条	1 分钟	安静	跟踪用；方位真值靠顶视或鱼眼摄像头标注
干扰单独录制	电视节目、空调 / 风扇、云台电机转动	3 种 ×2 位置	5 分钟	无人	与语音分开录，后期按指定 SIR 混合
真实混合（测试用）	真人唤醒 + 电视同时播放	2 人 ×12 方位	30 秒	电视开	不做后期混合，作为真实测试样本
长时误转专测	无人，电视持续播放	1 段	120 分钟	电视开	测误转率（次 / 小时）

房间（建议）

卧室类｜约 3 × 4 m ｜ RT60 约 0.3 s

客厅类｜约 5 × 6 m ｜ RT60 约 0.5 s

空旷大房间｜约 7 × 8 m ｜ RT60 约 0.8 s

会议室｜约 5 × 8 m ｜ RT60 约 0.6 s

数据量（建议） 每间房约 262 分钟（含 2 h 长时误转专测），4 类房间共约 17.5 h；明细见 Excel“数据量估算”

标注与元数据：方位真值、唤醒词起止和同步决定数据能否用；先试录半天检查再正式采集

每段录音需要记录

- 房间尺寸、家具布置照片、实测 RT60
- 阵列中心坐标与朝向；若阵列随云台转动，记录每段的云台角
- 每个点位的方位、距离、高度（地面贴标记）
- 说话人编号、性别、站 / 坐（不记录可识别个人身份的信息）
- 唤醒词起止时间（人工标注或唤醒模块日志）
- 干扰源类型、位置、播放音量；同一时钟下的多通道同步
- 移动段的轨迹视频（顶视或鱼眼摄像头）与时间戳

试录检查项

- 各通道同步、无丢帧
- 电平合适、无削波
- 方位标注与实测一致（抽查）
- 唤醒词起止时间可对齐
- 用现有算法跑一遍，误差在合理范围

合规

- 参与者知情同意
- 不记录可识别个人身份的信息
- 数据存储与使用范围按公司规定

时间计划（建议）： 11 月下旬定稿， 12 月中旬起采集， 1 月中下旬交付

阶段	时间	内容	负责	产出
方案定稿	11 月下旬	采集方案、数据格式、标注规范定稿；确认阵列 / 样机；启动录音合规流程（知情同意等）	定位侧	采集方案 v1
深圳准备与试录	12 月上中旬	设备、场地、标记与同步；试录半天，检查同步、电平、标注后修订方案	深圳同事 + 定位侧	试录数据与检查记录
正式采集	12 月中旬至 1 月上旬	4 类房间，约 8–10 个工作日（含搭建与标定）	深圳同事	原始多通道数据
整理与交付	1 月中下旬	切分、标注核对、按房间划分训练 / 测试	定位侧	训练集 / 测试集 v1
仿真数据（并行）	阵列几何确认后即开始	按目标几何生成约 200 h 仿真数据；先用公开数据和仿真训练候选模型	定位侧	仿真数据集、基线模型

前置依赖 阵列 / 样机确认（决定仿真几何与采集设备）；深圳人力与场地；录音合规流程。任一项延后，采集整体顺延。

对比规范：与竞品在同一测试场景、同一模型规格与算力开销下比较效果

条件	定义（建议）
同测试场景	固定测试集：自采数据中不参与训练的房间 + LOCATA Task 1 / 3 + 5 个演示场景；竞品样机在同一房间、同一点位实测
同模型规格	参数量、模型 / 资源文件大小与总运行内存对齐竞品；竞品定位模块的资源尚未公开，预算待 SDK 规格或样机实测后确定，暂不预设数值
同算力开销	同一平台、同一段多通道音频上测处理耗时与执行单元（ CPU / DSP / NPU ）；目标芯片确认后改在目标芯片上测
统一指标	Acc@10° 、粗大错误率、平均误差、首次定向时延、跟踪覆盖率、误转次数 / 小时

说明 竞品定位模块的内存、模型与耗时尚未公开（见竞品规格调研），预算暂不预设；优先申请思必驰 SDK 在同一段音频上做算法级对比，萤石以样机实测整机响应。测试房间不参与训练，避免高估效果。

待确认事项：阵列 / 样机与深圳资源决定采集能否按计划启动

1. demo 与采集用哪套阵列或样机（麦克风数量、间距、安装位置）
2. 深圳同事的人力、场地与可用时间
3. 录音的合规流程：参与者知情同意、数据存储与使用范围
4. 唤醒词文本，以及能否拿到唤醒模块对录音的起止时间
5. 目标芯片与算力预算（决定“同模型规格、同算力”的具体数字）